
Pontificia Universidad Javeriana

Facultad de Ingeniería
Departamento de Ingeniería de Sistemas

Proyecto de Investigación — Big Data

Análisis de la Relación Municipios y Resultados de las Pruebas Saber 11 en Colombia

Entrega 1: Entendimiento del Negocio y de los Datos

Integrantes: Ana Sofía Arboleda Convers
Miguel Santiago Espinosa Rodríguez
Nicolás Torres Roa
Alejandro Molina

Profesor: John Corredor, PhD

Repositorio: [https://github.com/anarboleda/
Proyecto-Big-Data-Conectividad-e-ICFES-en-Colombia](https://github.com/anarboleda/Proyecto-Big-Data-Conectividad-e-ICFES-en-Colombia)

Fecha: Bogotá D.C., 9 de abril de 2026

Índice

1. Entendimiento del Negocio	3
1.1. Marco Metodológico: CRISP-DM	3
1.2. Contexto Territorial: los Cuatro Municipios de Estudio	3
1.3. Indicadores Macroeconómicos de los Municipios de Estudio	4
1.4. Objetivos del Equipo de Consultoría	4
1.5. Criterios de Éxito del Proyecto	5
2. Selección de los Datos	6
3. Colección y Descripción de Datos	8
3.1. Infraestructura de Procesamiento: Clúster Apache Spark	8
3.2. Dataset 1: Internet Fijo por Tecnología y Segmento	9
3.2.1. Descripción general	9
3.2.2. Tipos de datos y descripción de atributos	10
3.3. Dataset 2: Resultados ICFES Saber 11	10
3.3.1. Descripción general	10
3.3.2. Variable derivada: puntaje promedio	10
3.3.3. Tipos de datos y descripción de atributos clave	11
3.4. Dataset 3: Distribución Histórica SGP Educación	11
3.4.1. Descripción general	11
3.4.2. Tipos de datos y descripción de atributos	12
3.5. Dataset 4: Matrícula por Nivel de Educación Superior	12
3.5.1. Descripción general	12
3.5.2. Tipos de datos y descripción de atributos	13
3.6. Dataset 5: Índice Municipal de Riesgo de Desastres (IMRC)	13
3.6.1. Descripción general	13
3.6.2. Preprocesamiento requerido	13
3.7. Dataset 6: Directorio de Bibliotecas Públicas	14
3.7.1. Descripción general	14
3.7.2. Tipos de datos y descripción de atributos clave	15
4. Exploración de Datos	16
4.1. Distribución del Puntaje Promedio ICFES por municipio	16
4.2. Accesos a Internet por Municipio	17
4.3. Accesos a Internet por Municipio sin Bogota	18

4.4. Numero de conexiones por tipo de tecnología	19
4.5. Numero de matriculas según nivel de educación	20
5. Reporte de Calidad de Datos	21
5.1. Metodología de Detección de Valores Faltantes	21
5.2. Resultados por Dataset	22
5.3. Técnicas de Tratamiento de Datos Faltantes	22
5.3.1. Eliminación de columnas	23
5.3.2. Imputación por moda	23
5.3.3. Imputación por mediana	23
5.3.4. Imputación por media	23
5.3.5. Imputación por modelo KNN (<i>K-Nearest Neighbors</i>)	24
5.3.6. Conversión de tipo como forma de limpieza	24
5.3.7. Interpolación temporal	24
5.3.8. Eliminación de registros	24
6. Planteamiento de Preguntas de Negocio	26
7. Filtros, Limpieza y Transformación Inicial	28
7.1. Filtros Aplicados	28
7.2. Transformaciones Realizadas	29
8. Bono A: Web Scraping — Datos de Población	30
9. Bono B: Datos Climáticos desde API OpenWeather	34
Conclusiones Preliminares	37

1. Entendimiento del Negocio

1.1. Marco Metodológico: CRISP-DM

El presente proyecto se desarrolla bajo la metodología **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), estándar reconocido internacionalmente para proyectos de análisis avanzado de datos. Esta metodología estructura el trabajo en seis fases iterativas: entendimiento del negocio, entendimiento de los datos, preparación de datos, modelado, evaluación y despliegue. La presente entrega corresponde integralmente a las dos primeras fases.

La fase de entendimiento del negocio no es un preámbulo formal: es la fase más crítica del ciclo. Definir mal el problema compromete toda la arquitectura analítica posterior, independientemente de la sofisticación de los modelos empleados. En este proyecto, el problema proviene de una necesidad real del Ministerio de Educación de Colombia: comprender por qué municipios con perfiles socioeconómicos radicalmente distintos presentan brechas tan pronunciadas en las Pruebas Saber 11, y qué papel juegan en ello la conectividad, la inversión pública en educación, el acceso a infraestructura cultural y las condiciones familiares de los estudiantes.

1.2. Contexto Territorial: los Cuatro Municipios de Estudio

La selección de los cuatro municipios conforma un gradiente socioeconómico y de conectividad intencionalmente contrastado, diseñado para maximizar el poder explicativo del análisis.

Bogotá D.C. actúa como caso de control. Con una población de 8.380.801 habitantes y una penetración de internet superior al 81,5 %, representa el escenario de mejor infraestructura digital y educativa del país, con un Índice de Pobreza Multidimensional (IPM) de tan solo 3,8 % para 2022 (Departamento Administrativo Nacional de Estadística (DANE), s.f.-b).

Buenaventura ilustra la paradoja estructural del Pacífico colombiano. A pesar de ser el principal puerto marítimo del país, el 82 % de su población se encuentra en condición de pobreza extrema, su tasa de desempleo alcanzó el 24,6 % en 2023 y su tasa de deserción escolar aumentó un 50 % entre 2021 y 2022 (Departamento Administrativo Nacional de Estadística (DANE), s.f.-a).

Riohacha, capital de La Guajira, registra un IPM departamental de 42,9 % para 2022 —triplicando la cifra nacional— y un índice de calidad de internet de apenas 45,49 sobre

100, entre los más bajos del país (Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC), s.f.). Su contexto étnico Wayuu añade una dimensión de análisis sobre la intersección entre diversidad cultural y brecha educativa.

Quibdó representa el extremo inferior del gradiente. Con tan solo 14,6 % de hogares conectados en el Chocó (Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC), s.f.), y con los puntajes ICFES consistentemente más bajos entre las capitales departamentales, su inclusión es indispensable para anclar el análisis en el escenario de mayor rezago acumulado.

1.3. Indicadores Macroeconómicos de los Municipios de Estudio

Tabla 1. Indicadores socioeconómicos comparativos de los municipios de estudio

Municipio	Dpto.	Pob. (2023)	IPM (%)	Acceso internet (%)
Bogotá D.C.	Cundinamar	8.380.801	3,8	81,5
Buenaventura	Valle	440.882	>40	~79 (Valle)
Riohacha	La Guajira	315.023	42,9	—
Quibdó	Chocó	126.495	>35	14,6 (Chocó)
Colombia	—	52.215.503	12,9	63,9

IPM: Índice de Pobreza Multidimensional. Acceso internet: porcentaje de hogares con acceso fijo o móvil. Fuentes: Departamento Administrativo Nacional de Estadística (DANE), s.f.-b; Departamento Administrativo Nacional de Estadística (DANE), s.f.-a; Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC), s.f.

1.4. Objetivos del Equipo de Consultoría

Objetivo general: Diseñar una propuesta de priorización territorial que le permita al Ministerio de Educación identificar cuáles de los municipios evaluados (Bogotá, Riohacha, Quibdó y Buenaventura) requieren intervenciones urgentes en infraestructura tecnológica o asignación de recursos, basándose en las mayores brechas descubiertas durante el análisis de datos.

Objetivos específicos:

1. Consolidar y organizar la información sobre el acceso a internet, la cantidad de bibliotecas y el presupuesto educativo de Bogotá, Riohacha, Quibdó y Buenaventura, con el fin de entender claramente con qué herramientas cuenta cada territorio en la actualidad.
2. Determinar cómo influyen las condiciones microeconómicas de los estudiantes,

tales como el estrato de la vivienda y la disponibilidad de herramientas tecnológicas propias (como acceso a un computador o internet en casa), en los puntajes individuales obtenidos en las pruebas de Estado.

3. Identificar las correlaciones existentes entre la inversión histórica en educación, la penetración de internet fijo y la presencia de bibliotecas públicas frente al nivel educativo general y el rendimiento académico de cada territorio.
4. Analizar la relación integral entre el contexto territorial y el rendimiento en las Pruebas Saber 11, cruzando los hallazgos socioeconómicos y de infraestructura para establecer la evidencia empírica que fundamentará el plan de acción.

1.5. Criterios de Éxito del Proyecto

Criterios de éxito del negocio: El proyecto se considerará exitoso si permite identificar al menos tres combinaciones de variables con relación estadísticamente significativa sobre el puntaje ICFES; si genera una priorización territorial basada en evidencia para la asignación de recursos del Ministerio de Educación; y si las recomendaciones son interpretables por tomadores de decisiones no técnicos.

Criterios de éxito técnicos: El modelo predictivo supervisado debe alcanzar una métrica $R^2 > 0,60$ para el puntaje global ICFES. El coeficiente de correlación entre internet y puntaje ICFES debe ser estadísticamente significativo al nivel $p < 0,05$. El procesamiento distribuido sobre Apache Spark debe demostrar ventajas concretas de escalabilidad frente al procesamiento convencional en Python puro.

2. Selección de los Datos

Los seis conjuntos de datos seleccionados cubren cuatro dimensiones analíticas complementarias: infraestructura tecnológica, rendimiento académico, inversión pública y condiciones de riesgo territorial. Su selección responde directamente a los objetivos de consultoría definidos en la sección anterior.

Dataset	Fuente	Justificación de selección
Resultados Pruebas Saber 11 (ICFES)	ICFES Datos Abiertos	Es la variable objetivo del proyecto. Contiene puntajes individuales por módulo (inglés, lectura crítica, razonamiento cuantitativo, comunicación escrita y competencias ciudadanas) y variables socioeconómicas del estudiante (estrato, acceso a internet en el hogar, disponibilidad de computador, nivel educativo de los padres), lo que permite un análisis tanto agregado a nivel municipal como desagregado a nivel individual.
Penetración de Internet Fijo por Municipio	MinTIC Datos Abiertos	Variable independiente principal del proyecto. Reporta trimestre a trimestre el número de accesos por proveedor, tecnología (fibra, xDSL, cable, inalámbrico fijo) y velocidad de bajada/subida, lo que permite evaluar no solo la cobertura sino la calidad de la conectividad disponible en cada municipio.
Distribución Histórica SGP Educación	Departamento Nacional de Planeación	Permite determinar si una mayor inyección de recursos públicos en prestación de servicios, calidad educativa (matrícula y gratuidad) se traduce en mejoras medibles en los puntajes ICFES. Es la proxy más directa de la inversión estatal en educación a nivel municipal.

(Continuación)

Dataset	Fuente	Justificación
Matrícula por Nivel Educativo	MinEducación Datos Abiertos	Cuantifica la oferta de educación superior (técnica, tecnológica, universitaria, posgrado) y el número de IES con presencia en cada municipio. Un municipio con mayor oferta de educación superior suele contar con mejor infraestructura tecnológica y docente que irradia sobre la educación básica y media.
Directorio de Bibliotecas Públicas	Biblioteca Nacional de Colombia	Indicador de infraestructura física de aprendizaje. Permite contrastar si el acceso a espacios tradicionales de información y cultura compensa parcialmente la brecha digital en zonas de baja conectividad, y si la presencia de bibliotecas correlaciona con mejores resultados ICFES.
Índice Municipal de Riesgo de Desastres (IMRC)	Departamento Nacional de Planeación	Contextualiza la vulnerabilidad territorial de cada municipio ante amenazas como sequías, incendios forestales y déficit de lluvias. Un alto índice de riesgo puede implicar interrupciones en la prestación educativa y en la infraestructura de telecomunicaciones, lo que lo convierte en una variable mediadora relevante en el modelo. (Departamento Nacional de Planeación (DNP), s.f.-a)

Tabla 2. Conjuntos de datos utilizados en el proyecto

Nota metodológica

Los conjuntos de datos aquí listados pueden ser ajustados en la Entrega 2 si el análisis exploratorio revela que algún dataset no aporta varianza explicativa suficiente para el objetivo de negocio. Particularmente, se evaluará si la granularidad temporal del dataset de SGP es compatible con la del dataset de ICFES para un análisis longitudinal robusto.

3. Colección y Descripción de Datos

3.1. Infraestructura de Procesamiento: Clúster Apache Spark

Infraestructura del clúster

El procesamiento del proyecto se ejecuta sobre un clúster Apache Spark propio (**Spark v3.5.8**), desplegado en un servidor Jupyter conectado al nodo master mediante la dirección `spark://10.43.97.205:7077`. La configuración utiliza el modo de planificación FAIR, que permite que múltiples usuarios compartan recursos de forma concurrente y equitativa durante las sesiones de trabajo. El nombre de la aplicación registrada en el clúster es `Stroke_MolinaSPARK`, heredado del entorno del servidor del curso.

```
1 import findspark
2 findspark.init()    # Conecta Python con la instalacion local de Spark
3
4 from pyspark import SparkContext, SparkConf
5 from pyspark.sql import SparkSession
6
7 configura = SparkConf()
8 # Modo FAIR: multiples usuarios comparten recursos de forma concurrente
9 configura.set("spark.scheduler.mode", "FAIR")
10 configura.set("spark.scheduler.allocation",
11              "/Almacen/Spark/conf/fairschedulr.xml")
12 # Direccion del nodo master del cluster
13 configura.setMaster("spark://10.43.97.205:7077")
14 configura.setAppName("BigData_PUJ_EntregaUno")
15
16 spark = SparkSession.builder.config(conf=configura).getOrCreate()
```

Listing 1. Configuración e inicialización del clúster Apache Spark propio

Una vez establecida la sesión, los datasets se cargan primero como DataFrames de pandas para aprovechar la lectura nativa de CSV y luego se convierten a DataFrames de Spark mediante `createDataFrame()`, metodología que garantiza la inferencia correcta de esquemas antes del procesamiento distribuido.

```
1 import pandas as pd
2
3 # Carga desde el sistema de archivos del servidor Jupyter
4 internet_pd =
5     pd.read_csv("/home/estudiante/Proyecto/internet_filtrado_municipios.csv")
```

```
5 matricula_pd =  
    pd.read_csv("/home/estudiante/Proyecto/nivel_educativo_filtrado_municipios.csv")  
6 imrc_pd =  
    pd.read_csv("/home/estudiante/Proyecto/imrc_filtrado_municipios.csv")  
7 icfes_pd =  
    pd.read_csv("/home/estudiante/Proyecto/icfes_filtrado_municipios.csv")  
8 educacion_pd =  
    pd.read_csv("/home/estudiante/Proyecto/ResumenDistribucionSGPHistoricoEducacion.csv",  
        sep=";")  
9 bibliotecas_pd =  
    pd.read_csv("/home/estudiante/Proyecto/bibliotecas_filtrado_municipios.csv")  
10  
11 # Conversion a DataFrames distribuidos de Spark  
12 internet_df = spark.createDataFrame(internet_pd)  
13 matricula_df = spark.createDataFrame(matricula_pd)  
14 imrc_df = spark.createDataFrame(imrc_pd)  
15 icfes_df = spark.createDataFrame(icfes_pd)  
16 educacion_df = spark.createDataFrame(educacion_pd)  
17 bibliotecas_df = spark.createDataFrame(bibliotecas_pd)
```

Listing 2. Carga de los seis datasets y conversión a DataFrames de Spark

3.2. Dataset 1: Internet Fijo por Tecnología y Segmento

3.2.1. Descripción general

Fuente oficial MinTIC. Reporta trimestralmente el número de accesos a internet fijo en Colombia desagregado por proveedor, municipio, tecnología de conexión y velocidad contratada. Tras filtrar los cuatro municipios de estudio, el dataset contiene registros desde 2014 hasta 2023.

3.2.2. Tipos de datos y descripción de atributos

Tabla 3. Esquema del dataset de internet fijo (obtenido con `printSchema()`)

Atributo	Tipo Spark	Descripción
AÑO	LongType	Año del trimestre reportado
TRIMESTRE	LongType	Trimestre (1 a 4)
PROVEEDOR	StringType	Nombre del ISP (ej. Claro, ETB, Tigo)
COD_DEPARTAMENTO	DoubleType	Código DANE del departamento
DEPARTAMENTO	StringType	Nombre del departamento
COD_MUNICIPIO	DoubleType	Código DIVIOLA del municipio
MUNICIPIO	StringType	Nombre del municipio
SEGMENTO	StringType	Tipo de cliente (Residencial / Empresarial)
TECNOLOGIA	StringType	Tecnología de acceso (Fibra, xDSL, Cable, Inalámbrico fijo)
VELOCIDAD_BAJADA	StringType	Velocidad de descarga contratada (Mbps)
VELOCIDAD_SUBIDA	StringType	Velocidad de carga contratada (Mbps)
No DE ACCESOS	LongType	Número de suscripciones activas en el período

Fuente: Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC), s.f. Sin valores faltantes detectados

3.3. Dataset 2: Resultados ICFES Saber 11

3.3.1. Descripción general

Dataset de microdatos individuales del ICFES. Cada registro corresponde a un estudiante que presentó las Pruebas Saber 11. Contiene tanto los puntajes por módulo como un bloque de variables socioeconómicas del núcleo familiar, lo que permite análisis tanto a nivel individual como agregado por municipio. El dataset filtrado para los cuatro municipios del estudio contiene **344.028 registros** con **56 columnas**.

3.3.2. Variable derivada: puntaje promedio

Dado que el ICFES no publica un puntaje global único en el archivo de microdatos, se calculó una variable derivada como promedio aritmético de los cinco módulos evaluados:

```
1 icfes_pd["PROMEDIO"] = icfes_pd[[
2     "MOD_INGLES_PUNT",
3     "MOD_LECTURA_CRITICA_PUNT",
4     "MOD_RAZONA_CUANTITAT_PUNT",
5     "MOD_COMUNI_ESCRITA_PUNT",
```

```
6 "MOD_COMPETEN_CIUADADA_PUNT"
7 ]] .mean(axis=1)
```

Listing 3. Cálculo del puntaje promedio por estudiante

3.3.3. Tipos de datos y descripción de atributos clave

Tabla 4. Atributos clave del dataset ICFES (selección de las 56 columnas)

Atributo	Tipo	Descripción
PERIODO	LongType	Año y semestre de la prueba (ej. 20231)
ESTU_MCPIO_RESIDE	StringType	Municipio de residencia del estudiante
FAMI ESTRATOVIVIENDA	StringType	Estrato socioeconómico del hogar (1–6)
FAMI_TIENEINTERNET	StringType	¿Tiene internet en el hogar? (Sí/No)
FAMI_TIENECOMPUTADOR	StringType	¿Tiene computador en el hogar? (Sí/No)
FAMI_EDUCACIONPADRE	StringType	Nivel educativo del padre
FAMI_EDUCACIONMADRE	StringType	Nivel educativo de la madre
ESTU_HORASSEMANTRABAJ	StringType	Horas semanales que trabaja el estudiante
INST_ORIGEN	StringType	Carácter del colegio (Oficial / No oficial)
MOD_INGLES_PUNT	DoubleType	Puntaje módulo inglés
MOD_LLECTURA_CRITICA_PU	LongType	Puntaje módulo lectura crítica
MOD_RAZONA_CUANTITAT_F	LongType	Puntaje módulo razonamiento cuantitativo
MOD_COMUNI_ESCRITA_PUN	DoubleType	Puntaje módulo comunicación escrita
MOD_COMPETEN_CIUADADA_F	LongType	Puntaje módulo competencias ciudadanas
PROMEDIO	Float64	Promedio de los cinco módulos (variable derivada)

Fuente: Instituto Colombiano para la Evaluación de la Educación (ICFES), s.f. Total 56 columnas, 344.028 registros.

3.4. Dataset 3: Distribución Histórica SGP Educación

3.4.1. Descripción general

Registro histórico de las transferencias del Sistema General de Participaciones (SGP) asignadas al sector educación. Incluye los componentes de Prestación de Servicios, Calidad

general, Calidad (Gratuidad) y Calidad (Matrícula). Es la fuente más directa para medir la inversión pública en educación a nivel municipal. Archivo con separador “;”.

3.4.2. Tipos de datos y descripción de atributos

Tabla 5. Esquema del dataset SGP Educación

Atributo	Tipo Spark	Descripción
Año	LongType	Año fiscal de la distribución
Prestación Servicios	StringType	Recursos asignados para nómina y funcionamiento educativo
Calidad	StringType	Total de recursos para mejora de la calidad educativa
Calidad (Gratuidad)	StringType	Recursos específicos para gratuidad educativa
Calidad (Matrícula)	StringType	Recursos específicos para subsidios de matrícula
Unnamed: 5	DoubleType	Columna vacía (100 % nulos — se eliminará)
Unnamed: 6	DoubleType	Columna vacía (100 % nulos — se eliminará)
Fuente: Departamento Nacional de Planeación (DNP), s.f.-b.		

3.5. Dataset 4: Matrícula por Nivel de Educación Superior

3.5.1. Descripción general

Contiene la matrícula anual en educación superior por municipio y nivel académico (técnica profesional, tecnológica, universitaria, especialización, maestría y doctorado), junto con el número de IES con oferta activa. Permite caracterizar el ecosistema de educación superior de cada municipio como variable proxy de capital humano e infraestructura tecnológica territorial.

3.5.2. Tipos de datos y descripción de atributos

Tabla 6. Esquema del dataset de matrícula en educación superior

Atributo	Tipo Spark	Descripción
AÑO	LongType	Año del registro
Código delDepartamento	LongType	Código DANE del departamento
Nombre del Departamento	LongType	Código del dpto. (requiere corrección de tipo)
Código delMunicipio	LongType	Código DIVIPOLA del municipio
Nombre del Municipio	StringType	Nombre del municipio
TECNICA PROFESIONAL	DoubleType	Estudiantes en nivel técnico profesional
TECNOLOGICA	StringType	Estudiantes en nivel tecnológico
UNIVERSITARIA	StringType	Estudiantes en nivel universitario
ESPECIALIZACION	DoubleType	Estudiantes en especialización
MAESTRIA	DoubleType	Estudiantes en maestría
DOCTORADO	DoubleType	Estudiantes en doctorado
IES CON OFERTA	LongType	Número de IES con oferta activa
MUNICIPIO_LIMPIO	StringType	Nombre normalizado (transformación T4)

Fuente: Ministerio de Educación Nacional (MEN), s.f. Nulos detectados: TECNOLÓGICA y UNIVERSITARIA con 1,1

3.6. Dataset 5: Índice Municipal de Riesgo de Desastres (IMRC)

3.6.1. Descripción general

Dataset del DNP que clasifica a los municipios según su exposición y vulnerabilidad ante amenazas de sequía extrema, incendios forestales y déficit de lluvias, incorporando componentes socioeconómicos y de gestión institucional. El atributo clave para el análisis es el **IMRC_D** (Índice de riesgo ajustado por capacidades), disponible como variable numérica continua en escala $[0, 1]$.

3.6.2. Preprocesamiento requerido

Las columnas de índices se almacenan originalmente como texto con comas decimales, lo que requiere una conversión explícita antes de la inferencia del esquema en Spark:

```
1 cols_imrc = [
```

```
2     "Indice de Riesgo de Desastres - Sequia Extrema",
3     "Indice de Riesgo de Desastres Incendio Forestal",
4     "Indice de Riesgo de Desastres - Deficit de lluvias",
5     "Indice de Capacidades - Deficit de lluvias",
6     "Indice de riesgo de desastres ajustado por capacidades (IMRC_D)"
7 ]
8
9 for col in cols_imrc:
10     imrc_pd[col] = (
11         imrc_pd[col]
12         .astype(str)
13         .str.replace(",", ".", regex=False)    # Coma decimal -> punto
14         .str.replace("%", "", regex=False)     # Remover simbolo porcentaje
15         .str.strip()
16     )
17     imrc_pd[col] = pd.to_numeric(imrc_pd[col], errors="coerce")
```

Listing 4. Conversión de columnas IMRC de texto a numérico

3.7. Dataset 6: Directorio de Bibliotecas Públicas

3.7.1. Descripción general

Directorio oficial de la Red Nacional de Bibliotecas Públicas (RNBP), administrado por el Ministerio de Cultura. Contiene información geográfica y de contacto de cada biblioteca activa en Colombia. Para el análisis se utilizará la variable **conteo de bibliotecas por municipio** como indicador de infraestructura cultural física de aprendizaje.

3.7.2. Tipos de datos y descripción de atributos clave

Tabla 7. Atributos clave del directorio de bibliotecas públicas

Atributo	Tipo Spark	Descripción
CUB	LongType	Identificador único de la biblioteca
CODIGO DANE	LongType	Código DANE del municipio
DEPARTAMENTO	StringType	Nombre del departamento
MUNICIPIO	StringType	Nombre del municipio
CENTRO POBLADO	StringType	Centro poblado donde se ubica
NATURALEZA DE LA BIBLIOTECA	StringType	Pública / Privada / Mixta
TIPO DE BIBLIOTECA	StringType	Municipal / Comunal / Escolar
NOMBRE DE LA BIBLIOTECA	StringType	Nombre oficial de la institución
ESTADO DE LA BIBLIOTECA	StringType	Activa / Inactiva
LATITUD	StringType	Coordenada de latitud (requiere conversión)
LONGITUD	StringType	Coordenada de longitud (requiere conversión)
Fuente: Biblioteca Nacional de Colombia, s.f.		

4. Exploración de Datos

Se presentan a continuación los análisis exploratorios generados mediante PySpark y las bibliotecas de visualización Matplotlib y Seaborn sobre el clúster Apache Spark del proyecto.

4.1. Distribución del Puntaje Promedio ICFES por municipio




Figura 1. Diagrama de barras de los promedios ICFES por municipio

La gráfica muestra una brecha clara entre Bogotá (~155 puntos) y los demás municipios. Riohacha (~132) y Buenaventura (~129) quedan en un rango intermedio similar entre sí, mientras Quibdó (~119) ocupa el último lugar. Esto confirma el gradiente socioeconómico intencionado en la selección de municipios: a mayor desarrollo e infraestructura, mejor desempeño académico. Teniendo una diferencia de cerca de 35 puntos entre el municipio con menor puntaje (Quibdó) y el de mayor puntaje (Bogotá)

4.2. Accesos a Internet por Municipio




Figura 2. Diagrama de barras sobre la cantidad de puntos de acceso por municipio

Bogotá domina de forma aplastante con más de 50 millones de conexiones acumuladas, mientras Buenaventura, Riohacha y Quibdó apenas son visibles en la escala. Esto evidencia por qué fue necesario generar la Figura 3. Dado que Bogotá actúa como un 'outlier' o dato

atípico que distorsiona cualquier comparación directa

4.3. Accesos a Internet por Municipio sin Bogota





Figura 3. Diagrama de barras de los promedios ICFES por municipio sin Bogota

Al excluir Bogotá, emerge una diferencia más visible: Buenaventura (660.000) supera a Riohacha (620.000) y ambas estando considerablemente por encima de Quibdó (440.000).

4.4. Numero de conexiones por tipo de tecnología



— 19 —
Figura 4. Diagrama de barras del numero de conexiones por tipo de tecnología

Cable es la tecnología dominante con alrededor de más de 27 millones de conexiones, seguida por Fiber to the Home (FTTH, 12 millones) y xDSL (8 millones). Esto refleja en buena medida la gran cantidad de tipos de tecnologías que se usan actualmente teniendo a las tecnologías satelital, WiFi y WiMAX con una presencia mínima, lo que indica que las zonas rurales y periféricas de los municipios siguen sin cobertura efectiva de internet.

4.5. Numero de matriculas según nivel de educación




Figura 5. Diagrama de barras apiladas sobre la cantidad de personas matriculadas a una institución educativa según nivel de educación

5. Reporte de Calidad de Datos

5.1. Metodología de Detección de Valores Faltantes

Para la detección sistemática de valores faltantes se implementó la función `resumen_nulos()`, aplicada sobre los DataFrames de pandas antes de su conversión a Spark. Esta función calcula tanto el conteo absoluto como el porcentaje de nulos por columna, ordenando los resultados de mayor a menor porcentaje para facilitar la priorización de la limpieza.

```
1 def resumen_nulos(df):
2     nulos = df.isnull().sum()
3     porcentaje = (nulos / len(df)) * 100
4     resumen = pd.DataFrame({
5         "Nulos": nulos,
6         "Porcentaje (%)": porcentaje.round(6)
7     })
8     return resumen[resumen["Nulos"] > 0].sort_values(
9         "Porcentaje (%)", ascending=False
10    )
11
12 resumen_nulos(icfes_pd)
13 resumen_nulos(matricula_pd)
14 resumen_nulos(educacion_pd)
```

Listing 5. Función para el reporte de valores faltantes por columna

5.2. Resultados por Dataset

Tabla 8. Resumen de valores faltantes detectados por dataset

Dataset	Variable	Nulos	%	Técnica propuesta
ICFES	ESTU_COD_COLE_MCPIO_TE	136.194	39,62	Eliminar columna
ICFES	ESTU_COLE_TERMINO	125.988	36,65	Eliminar columna
ICFES	FAMI_TIENEAUTOMOVIL	18.778	5,46	Imputar por moda
ICFES	FAMI_TIENELAVADORA	17.091	4,97	Imputar por moda
ICFES	FAMI_TIENECOMPUTADOR	16.496	4,80	Imputar por moda
ICFES	ESTU_HORASSEMANATRABAJ	14.450	4,20	Imputar por moda
ICFES	FAMI ESTRATO VIVIENDA	14.190	4,13	Imputar por moda
ICFES	FAMI_TIENEINTERNET	12.371	3,60	Imputar por moda
ICFES	MOD_COMUNI_ESCRITA_PUN	12.736	3,70	Imputar por mediana
ICFES	MOD_INGLES_PUNT	44	0,01	Imputar por mediana
Internet	Ninguna	0	0 %	N/A
Matrícula	TECNOLOGICA	2	1,19	Imputar por mediana
Matrícula	UNIVERSITARIA	2	1,19	Imputar por mediana
SGP Educación	Unnamed: 5	6	100 %	Eliminar columna
SGP Educación	Unnamed: 6	6	100 %	Eliminar columna
IMRC	Índices numéricos	Varios	Varios	Conversión de tipo (coma a punto)

5.3. Técnicas de Tratamiento de Datos Faltantes

La selección de la técnica de tratamiento depende del porcentaje de nulos, el tipo de variable (numérica continua, categórica ordinal, texto identificador) y el rol que desempeña

en el análisis. A continuación se describen las técnicas disponibles y su aplicación en este proyecto.

5.3.1. Eliminación de columnas

Se aplica cuando una columna presenta un porcentaje de valores nulos superior al 80 % o cuando su contenido no aporta información analítica relevante. En este proyecto se eliminan:

- `ESTU_COD_COLE_MCPIO_TERMINO` y `ESTU_COLE_TERMINO` del dataset ICFES (39–37 % de nulos, y son identificadores del colegio donde el estudiante cursó grado 11, no relevantes para el análisis de puntajes).
- `Unnamed: 5` y `Unnamed: 6` del dataset SGP (100 % de nulos — columnas vacías generadas al exportar el archivo desde Excel).

5.3.2. Imputación por moda

Técnica adecuada para **variables categóricas** o variables binarias (Sí/No) con menos del 10 % de valores faltantes, donde la categoría predominante es conocida y representativa del conjunto. Se aplica a las variables familiares del ICFES: `FAMI_TIENEINTERNET`, `FAMI_TIENECOMPUTADOR`, `FAMI_TIENELAVADORA`, `FAMI_TIENEAUTOMOVIL`, `FAMI ESTRATOVIVIENDA` y `ESTU_HORASSEMANATRABAJA`. La justificación es que, en contextos de baja conectividad como Quibdó o Riohacha, la moda de “No tiene internet” es representativa de la mayoría de los hogares.

5.3.3. Imputación por mediana

Técnica adecuada para **variables numéricas continuas** con menos del 10 % de valores faltantes y distribuciones asimétricas, donde la media estaría sesgada por valores extremos. Se aplica a: `MOD_COMUNI_ESCRITA_PUNT`, `MOD_INGLES_PUNT` (dataset ICFES) y a `TECNOLOGICA` y `UNIVERSITARIA` (dataset Matrícula). La mediana es más robusta ante las diferencias pronunciadas de puntaje entre Bogotá y los demás municipios.

5.3.4. Imputación por media

Técnica válida para variables numéricas con distribución aproximadamente simétrica. Se considerará para variables del IMRC que presenten pocos nulos tras la conversión de tipo, siempre que la distribución no sea extremadamente asimétrica.

5.3.5. Imputación por modelo KNN (*K-Nearest Neighbors*)

Técnica avanzada para variables con entre 10 % y 30 % de nulos y fuerte relación con otras variables del dataset. No aplica directamente a los datasets actuales dada la baja proporción de nulos, pero se considera como opción de respaldo si en la etapa de integración de tablas emergen porcentajes de nulos más altos en las variables clave.

5.3.6. Conversión de tipo como forma de limpieza

Para el dataset IMRC, los valores numéricos estaban almacenados como cadenas de texto con coma decimal y símbolo de porcentaje. Esta situación no es un “valor faltante” propiamente, sino un problema de tipo de dato, que se resolvió mediante:

```
1 imrc_pd[col] = (  
2     imrc_pd[col]  
3     .astype(str)  
4     .str.replace(",", ".", regex=False)  
5     .str.replace("%", "", regex=False)  
6     .str.strip()  
7 )  
8 imrc_pd[col] = pd.to_numeric(imrc_pd[col], errors="coerce")
```

Listing 6. Limpieza de formato numérico en columnas IMRC

5.3.7. Interpolación temporal

Técnica aplicable a series de tiempo anuales o trimestrales donde el valor faltante está flanqueado por registros disponibles en períodos adyacentes. Se considera para el dataset de internet si en algún trimestre puntual de un municipio falta el conteo de accesos.

5.3.8. Eliminación de registros

Se aplica cuando una fila tiene más del 50 % de sus variables clave con valor nulo, y la imputación distorsionaría los análisis más que excluir el registro. En el dataset ICFES, los registros sin puntaje en más de dos módulos serán candidatos a eliminación, ya que el puntaje promedio calculado sería poco representativo.

Tabla 9. Valores faltantes detectados en el dataset ICFES

Variable	Nulos	Porcentaje (%)
ESTU_COD_COLE_MCPIO_TERMINO	136.194	39,62
ESTU_CODDANE_COLE_TERMINO	136.194	39,62
ESTU_COLE_TERMINO	125.988	36,65
FAMI_TIENEAUTOMOVIL	18.778	5,46
FAMI_TIENELAVADORA	17.091	4,97
FAMI_TIENECOMPUTADOR	16.496	4,80
ESTU_HORASSEMANTRABAJA	14.450	4,20
FAMI ESTRATOVIVIENDA	14.190	4,13
MOD_COMUNI_ESCRITA_DESEM	12.736	3,70
FAMI_TIENEINTERNET	12.371	3,60
FAMI_EDUCACIONMADRE	10.799	3,14
FAMI_EDUCACIONPADRE	10.605	3,08
ESTU_TIPODOCUMENTOSB11	6.557	1,91
ESTU_PAGOMATRICULABECA	3.001	0,87
ESTU_PAGOMATRICULACREDITO	2.978	0,87
ESTU_PAGOMATRICULAPROPIO	2.953	0,86
ESTU_PAGOMATRICULAPADRES	2.943	0,86
ESTU_VALORMATRICULAUNIVERSIDAD	2.871	0,84
MOD_COMUNI_ESCRITA_PUNT	1.819	0,53
MOD_INGLES_PUNT	44	0,01
MOD_INGLES_DESEM	44	0,01
ESTU_GENERO	43	0,01
ESTU_MCPIO_PRESENTACION	33	0,01
ESTU_COD_DEPTO_PRESENTACION	33	0,01
ESTU_DEPTO_PRESENTACION	33	0,01
ESTU_COD_MCPIO_PRESENTACION	33	0,01

Para el caso del Dataset de bibliotecas, los valores que hacen falta son valores los cuales no son requeridos para el proyecto, por lo que pueden ser descartados sin tener afectaciones a los resultados que se generen de este proyecto.

Tabla 10. Valores faltantes detectados en el dataset de Bibliotecas

Variable	Nulos	Porcentaje (%)
FAX	33	100,00
EXTENSIÓN	7	21,21
PÁGINA WEB DE LA BIBLIOTECA	3	9,09
LATITUD	1	3,03
LONGITUD	1	3,03

6. Planteamiento de Preguntas de Negocio

Pregunta PB1

¿Cuál ha sido la evolución trimestral del número de accesos a internet fijo en Bogotá, Buenaventura, Riohacha y Quibdó, y cómo varía la composición tecnológica (fibra óptica vs xDSL vs cable) entre municipios con distintos niveles de desarrollo?

Pregunta PB2

¿Existe correlación estadística significativa entre el nivel de acceso a internet fijo por cada 1.000 habitantes y el puntaje promedio en las Pruebas Saber 11, tanto a nivel municipal agregado como a nivel individual (datos FAMI_TIENEINTERNET)?

Pregunta PB3

¿En qué magnitud difieren los puntajes ICFES entre estudiantes que tienen acceso a internet en el hogar y quienes no lo tienen, controlando por el municipio de residencia y el estrato de la vivienda?

Pregunta PB4

¿Los municipios que recibieron mayor asignación histórica del SGP para educación presentan mejores puntajes en las Pruebas Saber 11? ¿Esta relación es significativa cuando se controla por el nivel de conectividad?

Pregunta PB5

¿La presencia y número de bibliotecas públicas en un municipio se asocia con mejores puntajes ICFES, especialmente en municipios con baja penetración de internet?

Pregunta PB6

¿El índice de riesgo de desastres (IMRC_D) tiene un efecto mediador sobre la relación entre conectividad e ICFES? ¿Los municipios con mayor riesgo ven ampliada su brecha educativa?

Pregunta PB7

¿Qué combinación de variables (internet en el hogar, estrato, nivel educativo de los padres, horas de trabajo del estudiante, carácter del colegio) tiene mayor poder predictivo individual sobre el puntaje promedio ICFES?

Pregunta PB8

¿El nivel de oferta de educación superior (número de IES y matrícula en educación universitaria) en un municipio se correlaciona con el rendimiento en las Pruebas Saber 11 de sus colegios de educación media?

7. Filtros, Limpieza y Transformación Inicial

Nota metodológica

Se presenta un avance del proceso de preparación de datos. El pipeline completo, incluyendo su aplicación integrada sobre todos los datasets combinados, se entregará en la Entrega 2.

7.1. Filtros Aplicados

1. **F1 — Normalización de nombres para el filtrado:** Dado que cada dataset usa convenciones distintas (“BOGOTÁ, D.C.” vs “BOGOTA” vs “Bogotá”), se implementó una función de normalización antes de aplicar el filtro. Esto garantiza que ningún registro del municipio quede excluido por diferencias de codificación.
2. **F2 — Selección de municipios de estudio:** Se retienen únicamente registros de Bogotá D.C., Buenaventura, Riohacha y Quibdó. Este filtro se aplicó sobre todos los datasets con nombres de municipio como llave de selección.
3. **F3 — Eliminación de columnas con 100 % de nulos:** Las columnas Unnamed: 5 y Unnamed: 6 del dataset SGP se eliminan por no contener información alguna.

```
1 import unicodedata
2
3 def limpiar(texto):
4     """Normaliza texto: elimina tildes, convierte a mayusculas,
5     quita espacios y saltos de linea."""
6     if isinstance(texto, str):
7         texto = texto.replace("\n", "").strip().upper()
8         texto = unicodedata.normalize("NFKD", texto)\
9             .encode("ascii", "ignore")\
10             .decode("utf-8")
11     return texto
12 return texto
13
14 # Aplicar normalizacion y filtrar por municipios de estudio
15 matricula_pd["MUNICIPIO_LIMPIO"] = matricula_pd["Nombre del
16     Municipio"].apply(limpiar)
17
18 municipios = ["BOGOTA", "QUIBDO", "RIOHACHA", "BUENAVENTURA"]
19 matricula_filtrado = matricula_pd[
20     matricula_pd["MUNICIPIO_LIMPIO"].str.contains(
```

```
20     "|".join(municipios), na=False
21 )
22 ]
```

Listing 7. Función de normalización de nombres de municipio y filtrado robusto

```
1 municipios_imrc = ["BOGOTÁ, D.C.", "QUIBDÓ", "RIOHACHA", "BUENAVENTURA"]
2
3 imrc_filtrado = imrc_pd[imrc_pd["Municipio"].isin(municipios_imrc)]
4 imrc_filtrado.to_csv("imrc_filtrado_municipios.csv", index=False)
```

Listing 8. Filtrado del dataset IMRC por municipio

7.2. Transformaciones Realizadas

1. **T1 — Cálculo del puntaje promedio ICFES:** Se crea la variable **PROMEDIO** como media aritmética de los cinco módulos de la prueba, dado que el archivo **dedatos** no incluye un puntaje global precalculado.

$$\text{PROMEDIO}_i = \frac{1}{5} \sum_{m=1}^5 P_{im}$$

donde P_{im} es el puntaje del estudiante i en el módulo m .

2. **T2 — Conversión de columnas numéricas en datasets de matrícula e IMRC:** Las columnas almacenadas como texto con comas decimales, puntos de miles o símbolos de porcentaje se convierten a tipo numérico mediante `pd.to_numeric(errors="coerce")`, que convierte los valores no convertibles a `NaN` para su posterior tratamiento.
3. **T3 — Estandarización de nombres de municipio:** Se crea la columna **MUNICIPIO_LIMPIO** en todos los datasets, con el nombre del municipio en mayúsculas, sin tildes y sin espacios redundantes, para permitir joins correctos entre tablas con convenciones de codificación distintas.

8. Bono A: Web Scraping — Datos de Población

```
1  # Importamos las librerías necesarias para comunicación con la web y manejo de
    archivos
2  import urllib.request
3  import os
4  import time
5
6  # Definimos la fuente: La API de Datos Abiertos del Gobierno Colombiano.
7  # Seleccionamos solo 3 columnas para optimizar el peso del archivo final.
8  url_fuente =
    "https://www.datos.gov.co/resource/gt2j-8ykr.csv?$limit=10000000&$select=departamento_nom,estad
9
10 # Nombre del archivo donde guardaremos los datos localmente
11 archivo_datos = "dataset_covid_completo.csv"
12
13 print("Descargando el archivo...")
14
15 # Marcamos el tiempo de inicio para medir el rendimiento de la descarga
16 tiempo_inicio = time.time()
17
18 try:
19     # urlretrieve descarga el archivo directamente al disco duro
20     urllib.request.urlretrieve(url_fuente, archivo_datos)
21     tiempo_fin = time.time()
22
23     # Calculamos el peso del archivo en Megabytes
24     peso_archivo = os.path.getsize(archivo_datos) / (1024 * 1024)
25
26     print(f"\nDescarga exitosa")
27
28 except Exception as e:
29     # Si se corta la conexión o ocurre algún error al momento de la descarga se
    mostrara:
30     print(f"\nError durante la descarga: {e}")
31
32 # Importamos las herramientas de Spark y de análisis local (Pandas)
33 from pyspark.sql import SparkSession
34 import pandas as pd
35
36 def ejecutar_procesamiento():
37     try:
38         # Configuramos la sesión de Spark dándole un nombre y asignando memoria
```

```
39     spark = SparkSession.builder \
40         .appName("Análisis_WebScraping") \
41         .config("spark.driver.memory", "4g") \
42         .getOrCreate()
43
44     # Leemos el archivo CSV usando Spark
45     df_spark = spark.read.csv(archivo_datos, header=True, inferSchema=True)
46
47     # Mostramos una pequeña muestra para demostrar la lectura exitosa
48     df_spark.show(10)
49
50     # Contamos cuántos millones de registros hay realmente
51     conteo_total = df_spark.count()
52
53     # Realizamos las transformaciones de Big Data
54     from pyspark.sql.functions import col, upper
55     resultado_spark = df_spark.withColumn("dep",
56         upper(col("departamento_nom"))) \
57         .groupBy("dep").count() \
58         .orderBy(col("count").desc())
59
60     return resultado_spark.limit(10).toPandas(), "Apache Spark Cluster"
61
62 except Exception as e:
63     # Leemos el archivo usando la memoria
64     df_pd = pd.read_csv(archivo_datos)
65
66     # Mostramos una pequeña muestra para demostrar la lectura exitosa en Pandas
67     print(df_pd.head(10))
68
69     # Aplicamos la lógica de limpieza y agrupación
70     df_pd['dep'] = df_pd['departamento_nom'].astype(str).str.upper()
71     res_pd = df_pd['dep'].value_counts().reset_index().head(10)
72     res_pd.columns = ['dep', 'count']
73
74     print("Análisis completo")
75     return res_pd, "Pandas"
76
77 # Ejecutamos la función y guardamos el resultado
78 df_final, motor_utilizado = ejecutar_procesamiento()
79
80 # Importamos librerías gráficas de alto nivel
81 import matplotlib.pyplot as plt
82 import seaborn as sns
```



```
83 # Configuramos el estilo visual del gráfico
84 plt.figure(figsize=(14, 7))
85 sns.set_style("whitegrid")
86
87 # Creamos el gráfico de barras usando Seaborn
88 # Usamos una paleta de colores llamativa ("viridis")
89 grafica = sns.barplot(data=df_final, x='dep', y='count', palette="viridis")
90
91 # Añadimos los títulos y etiquetas profesionales
92 plt.title(f'Top 10 Nacional: Distribución de Casos COVID-19',
93         fontsize=16, fontweight='bold', pad=20)
94 plt.ylabel("Número Total de Casos", fontsize=12)
95 plt.xlabel("Departamento / Distrito", fontsize=12)
96 plt.xticks(rotation=45)
97
98 # Bucle para poner los números exactos encima de cada barra
99 for p in grafica.patches:
100     grafica.annotate(f'{int(p.get_height()):,}',
101                     (p.get_x() + p.get_width() / 2., p.get_height()),
102                     ha='center', va='center',
103                     xytext=(0, 9),
104                     textcoords='offset points',
105                     fontsize=10,
106                     color='black',
107                     fontweight='bold')
108
109 # Ajustamos el diseño para que no se corten las etiquetas
110 plt.tight_layout()
111
112 # Mostramos el gráfico final
113 plt.show()
```

Listing 9. Extracción de datos de población municipal mediante web scraping




Figura 6. Distribución de la población en los 10 municipios con más casos de COVID-19.

9. Bono B: Datos Climáticos desde API OpenWeather

```
1 import requests
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5
6 # 1. Configuración
7 # Nota: Asegúrate de que la API Key ya esté activa (puede tardar 2 horas desde su
   creación)
8 api_key = "97e206527c2b35c4d3a7ea3217737ed9"
9 ciudades = ["Quibdo", "Riohacha", "Buenaventura", "Bogota"]
10 datos_clima = []
11
12 print("--- INICIANDO CONSULTA CLIMÁTICA ---")
13
14 # 2. Extracción con validación de respuesta
15 for ciudad in ciudades:
16     url =
17         f"http://api.openweathermap.org/data/2.5/weather?q={ciudad},CO&appid={api_key}&units=metric"
18     respuesta = requests.get(url)
19     datos = respuesta.json()
20
21     # Verificamos si la respuesta fue exitosa (Código 200)
22     if respuesta.status_code == 200:
23         temp = datos['main']['temp']
24         humedad = datos['main']['humidity']
25         datos_clima.append({"Ciudad": ciudad, "Temperatura (°C)": temp, "Humedad
   (%)": humedad})
26         print(f" {ciudad}: Datos recibidos.")
27     else:
28         # Si falla, imprimimos el error real de la API
29         print(f"{ciudad}: Error {respuesta.status_code} - {datos.get('message',
   'Error desconocido')}")
30
31 # 3. Procesamiento
32 if datos_clima:
33     df_clima = pd.DataFrame(datos_clima)
34
35 # 4. Visualización
36 plt.figure(figsize=(10, 6))
37 sns.set_style("whitegrid")
```

```
38     # Gráfico de barras para Temperatura
39     grafica = sns.barplot(data=df_clima, x='Ciudad', y='Temperatura (°C)',
40                           palette='coolwarm')
41
42     plt.title('Comparativa Climática: Extremos de Colombia', fontsize=15,
43              fontweight='bold')
44     plt.ylabel('Grados Celsius (°C)')
45     plt.xlabel('Ciudad')
46
47     # Etiquetas de valor sobre las barras
48     for p in grafica.patches:
49         grafica.annotate(f'{p.get_height()}°C',
50                         (p.get_x() + p.get_width() / 2., p.get_height()),
51                         ha='center', va='center', xytext=(0, 9),
52                         textcoords='offset points', fontweight='bold')
53
54     plt.tight_layout()
55     plt.show()
56
57     # Opcional: Mostrar también la humedad para aprovechar los datos de Quibdó
58     print("\nTabla comparativa final:")
59     print(df_clima.to_string(index=False))
60
61     print("\n--- PROCESO FINALIZADO CON ÉXITO ---")
62 else:
63     print("\nNo se pudo generar el gráfico")
```

Listing 10. Consulta de datos climáticos desde la API de OpenWeather)




Figura 7. Comparativa climatica de 4 municipios de Colombia

Conclusiones Preliminares

1. **Brecha digital pronunciada y estructural:** [Completar con los valores del reporte de nulos y estadísticos del dataset de internet — diferencia en número de accesos entre Bogotá y Quibdó.]
2. **El acceso a internet en el hogar importa a nivel individual:** [Completar con el análisis de FAMI_TIENEINTERNET y su correlación con PROMEDIO en el dataset ICFES.]
3. **Calidad de los datos es heterogénea entre fuentes:** El dataset ICFES presenta columnas con hasta 39,6 % de valores faltantes en variables de identificación del colegio de procedencia, mientras que el dataset de internet no registra ningún nulo. Esta asimetría en la calidad requiere un pipeline de limpieza diferenciado por dataset.
4. **Problemas de estandarización de nombres:** La misma entidad territorial aparece bajo múltiples variantes textuales a través de los seis datasets, lo que hace de la transformación T3 (normalización de nombres) un paso crítico para la integrabilidad de las fuentes en la Entrega 2.
5. **Variables climáticas como factor diferenciador:** [Completar con observación derivada del Bono B — diferencia entre el régimen de lluvias de Quibdó y el régimen semiárido de Riohacha, y su posible impacto sobre asistencia escolar e infraestructura de telecomunicaciones.]

Referencias

- Biblioteca Nacional de Colombia. (s.f.). *Directorio de Bibliotecas - Red Nacional de Bibliotecas Públicas*. Consultado el 7 de abril de 2026, desde <https://www.bibliotecanacional.gov.co/es-co/Footer/red-nacional-de-bibliotecas-publicas/directorio>
- Departamento Administrativo Nacional de Estadística (DANE). (s.f.-a). *DANE - Pobreza Monetaria*. Consultado el 7 de abril de 2026, desde <https://www.dane.gov.co/index.php/estadisticas-por-tema/pobreza-y-condiciones-de-vida/pobreza-monetaria>
- Departamento Administrativo Nacional de Estadística (DANE). (s.f.-b). *DANE - Pobreza Multidimensional*. Consultado el 7 de abril de 2026, desde <https://www.dane.gov.co/index.php/estadisticas-por-tema/pobreza-y-condiciones-de-vida/pobreza-multidimensional>
- Departamento Nacional de Planeación (DNP). (s.f.-a). *Índice Municipal de Gestión de Riesgo ajustado por capacidades*. Consultado el 8 de abril de 2026, desde https://dnp.gov.co/LaEntidad_/subdireccion-general-prospectiva-desarrollo-nacional/direccion-ambiente-desarrollo-sostenible/Paginas/indice-municipal-de-gestion-de-riesgo-ajustado-por-capacidades.aspx
- Departamento Nacional de Planeación (DNP). (s.f.-b). *SICODIS - Sistema de Distribución de Recursos*. Consultado el 7 de abril de 2026, desde <https://sicodis.dnp.gov.co/sgp-inicio>
- Instituto Colombiano para la Evaluación de la Educación (ICFES). (s.f.). *Resultados Únicos Saber Pro*. https://www.datos.gov.co/Educacion/Resultados-nicos-Saber-Pro/u37r-hjmu/about_data
- Ministerio de Educación Nacional (MEN). (s.f.). *Estadísticas de Matrícula por Municipios*. Consultado el 7 de abril de 2026, desde https://www.datos.gov.co/Educacion/MEN_ESTADISTICAS-MATRICULA-POR-MUNICIPIOS_ES/y9ga-zwzy/data_preview
- Ministerio de Tecnologías de la Información y las Comunicaciones (MinTIC). (s.f.). *Internet Fijo: Accesos por Tecnología y Segmento*. Consultado el 7 de abril de 2026, desde https://www.datos.gov.co/Ciencia-Tecnologia-e-Innovacion/Internet-Fijo-Accesos-por-tecnologia-y-segmento/n48w-gutb/data_preview