

PROYECTO · BIG · DATA

Entrega 2: Preparación de datos, Modelado y Presentación de Resultados

Procesamiento de Alto Volumen de Datos

John Corredor, PhD · Grupo 16 · Pontificia Universidad Javeriana · 2026



6 FUENTES DE DATOS



ICFES · INTERNET
SGP · RIESGO



SPARK MLLIB
RANDOM FOREST +
KMEANS



8 PREGUNTAS
DE NEGOCIO



RECOMENDACIONES
AL MEN

OBJETIVO Y METODOLOGÍA

OBJETIVO DE NEGOCIO



Apoyar al Ministerio de Educación con evidencia analítica para mejorar indicadores educativos territoriales.



Identificar municipios con brechas de conectividad y rendimiento



Analizar relación entre internet en hogar y puntajes ICES



Evaluar estrato, computador, presupuesto y riesgo ambiental



Construir modelos ML para predecir rendimiento y segmentar perfiles

METODOLOGÍA CRISP-DM

Entendimiento del negocio

Problema MEN + preguntas de negocio

Entendimiento de datos

ICES, internet, SGP, riesgo, bibliotecas

Preparación de datos

Limpieza, filtros, imputación, transformación

Modelado

Random Forest Regressor + K-Means MLlib

Evaluación

RMSE, MAE, R^2 , Silhouette, parámetros

Presentación

Análisis, conclusiones y recomendaciones

FUENTES DE DATOS



ICFES SABER 11

Puntajes por módulo, municipio, estrato, internet, computador, origen inst.

Variable objetivo: rendimiento académico



INTERNET POR MUNICIPIO

Municipio, año, tecnología, número de accesos

Conectividad territorial comparativa



SGP EDUCACIÓN

Año, prestación de servicios, calidad, gratuidad, matrícula

Inversión pública educativa por municipio



ÍNDICE MUNICIPAL DE RIESGO

Exposición a sequía extrema, variables de riesgo territorial

Impacto ambiental en el aprendizaje



BIBLIOTECAS PÚBLICAS

Municipio, nombre, ubicación

Infraestructura física de acceso a info



EDUCACIÓN SUPERIOR

Municipio, matrícula universitaria

Ecosistema educativo local

FILTROS Y TRANSFORMACIONES FINALES

F1 Validación de puntajes críticos



```
icfes_df.filter(col("MOD_LECTURA_CRITICA_PUNT").isNotNull())
```

Conserva registros con Lectura Crítica y Razonamiento Cuantitativo válidos. Garantiza consistencia académica.

F2 Eliminación de columnas redundantes



```
sgp_df.drop("Unnamed: 5", "Unnamed: 6")
```

Elimina columnas sin valor analítico del SGP e ICFES. Reduce ruido y mejora legibilidad.

T1 Tratamiento de valores faltantes



```
icfes.fillna({"FAMI_TIENEINTERNET": "No", ...})
```

Imputación de variables familiares: internet, computador y estrato. Conserva volumen de datos.

T2 Integración de fuentes de datos



```
trim(upper(MCPIO)) == trim(upper(MUNICIPIO))
```

JOIN entre ICFES, internet, SGP y riesgo territorial mediante normalización de nombres de municipio.

T3 Internet per cápita




```
INTERNET_PER_CAPITA_1000 = (accesos / pob) * 1000
```

Permite comparar conectividad entre municipios de distinto tamaño. Medida relativa más justa.

PB1: Accesos por Tecnología - Buenaventura 2017



PB2: Internet en Hogar vs Rendimiento (Buenaventura)



PB3: Puntajes por Estrato e Internet (Buenaventura)

Estrato	Internet	Puntaje
Estrato 1	Sin info	123.71
Estrato 1	No	126.66
Estrato 1	Sí	129.40
Estrato 2	Sin info	121.xx
Estrato 2	No	126.xx

PB4: SGP Educación vs Rendimiento ICFES

Municipio	SGP	Connect.	ICFES
Riohacha	Calidad	0.156	132.2
Buenaventura	Calidad	0.147	128.9
Quibdó	Calidad	0.533	118.3

➤ Mayor conectividad no garantiza mayor rendimiento: la inversión debe articularse con factores pedagógicos.

PB5: Bibliotecas vs Conectividad

Municipio	Bibliotecas	Internet	ICFES
Riohacha	2	0.156	132.2
Buenaventura	3	0.147	128.9

Las bibliotecas son apoyo potencial, pero su impacto depende de internet, equipos y acompañamiento.

PB6: Riesgo Territorial vs Rendimiento


Municipio	Sequía	Connect.	ICFES
Quibdó	0.74	0.533	118.3
Riohacha	0.67	0.156	132.2
Buenaventura	0.66	0.147	128.9

Mayor riesgo ambiental → menor rendimiento. El territorio importa.

PB7: Perfiles Socioeconómicos

Estrato	PC	Internet	Institución	Score
4	Sí	No	No of. fund.	224.6
1	Sí	No	Oficial mun.	191.0
1	Sí	S/I	No of. fund.	174.6
3	No	Sí	No of. mun.	170.2

PB8: Educación Superior vs Media



MODELOS DE APRENDIZAJE DE MÁQUINA



RANDOM FOREST REGRESSOR

Supervisado · Variable objetivo: PROMEDIO

```
rf = RandomForestRegressor(  
    numTrees=50, maxDepth=5,  
    labelCol='PROMEDIO', seed=42  
)  
modelo_rf = rf.fit(train_df)
```

- Maneja relaciones no lineales entre variables
- Robusto frente a ruido y valores atípicos
- Compatible con variables numéricas y categóricas
- Escalable en Spark MLlib

División: 80% entrenamiento / 20% prueba

Parámetros: numTrees ∈ {20,50,100} · maxDepth ∈ {3,5,8}



K-MEANS CLUSTERING

No Supervisado · Agrupación por perfiles

```
kmeans = KMeans(  
    k=3, seed=42,  
    featuresCol='features'  
)  
clusters = kmeans.fit(df_preparado)
```

- Segmenta municipios o estudiantes sin etiqueta
- Identifica perfiles prioritarios para intervención
- Eficiente y escalable en grandes volúmenes
- Evaluado con métrica Silhouette

Valores de K probados: $k \in \{2, 3, 4, 5, 6\}$

Selección: mejor Silhouette + interpretabilidad de negocio

PREPARACIÓN DE DATOS Y MÉTRICAS

PIPELINE DE PREPARACIÓN →



VARIABLES SELECCIONADAS

PROMEDIO	Num.	Variable objetivo
INTERNET_PER_CAPITA_1000	Num.	Conectividad territorial
NO DE ACCESOS	Num.	Infraestructura internet
POBLACION_MUNICIPIO	Num.	Control de tamaño municipal
SGP_CALIDAD_PRESUPUESTO	Num.	Inversión educativa
Exposición a Sequía Extrema	Num.	Vulnerabilidad territorial
FAMI_TIENEINTERNET	Cat.	Conectividad en hogar
FAMI_TIENECOMPUTADOR	Cat.	Equipo tecnológico
FAMI_ESTRATOVIVIENDA	Cat.	Condición socioeconómica
INST_ORIGEN	Cat.	Tipo institución

MÉTRICAS DE EVALUACIÓN

RMSE

$$\sqrt{\sum (y_i - \hat{y}_i)^2 / n}$$

Error cuadrático medio. Penaliza desviaciones grandes. Menor = mejor.

MAE

$$\sum |y_i - \hat{y}_i| / n$$

Error absoluto promedio en puntos ICFES. Más interpretable.

R²

$$1 - SS_{res} / SS_{tot}$$

Proporción de variabilidad explicada por el modelo. Cercano a 1 = mejor.

Silhouette

$$S(i) = (b(i) - a(i)) / \max(a,b)$$

Separación y compacidad de clusters K-Means. Cercano a 1 = mejor.

Prueba de parámetros RF: numTrees ∈ {20,50,100} × maxDepth ∈ {3,5,8} → 9 combinaciones

RECOMENDACIONES AL MINISTERIO DE EDUCACIÓN



01

Priorizar conectividad residencial

Fortalecer programas de internet subsidiado para estudiantes de bajos recursos en territorios rezagados.



02

Dotar de dispositivos

Complementar conectividad con computadores. Sin equipo, el acceso a red no se traduce en aprendizaje.



03

Analizar por indicadores per cápita

Comparar municipios usando conectividad relativa, no absoluta, para evitar lecturas engañosas.



04

Articular inversión SGP con metas TIC

La inversión educativa debe asociarse a proyectos medibles: infraestructura, capacitación y recursos digitales.



05

Intervenciones diferenciadas por cluster

Usar los perfiles K-Means para diseñar estrategias específicas según nivel de riesgo y rendimiento.



06

Fortalecer bibliotecas y espacios digitales

Habilitar bibliotecas como nodos de acceso con internet, equipos y acompañamiento pedagógico.

CONCLUSIONES Y LIMITACIONES

CONCLUSIONES CLAVE

Multifactorial

El rendimiento académico no depende de un único factor: conectividad, socioeconómico, dispositivos, origen institucional e inversión pública actúan en conjunto.

Brecha digital-educativa

Estudiantes con internet en hogar presentan mejor rendimiento promedio. La brecha tiene dimensión digital, social e institucional.

Conectividad $\neq$ Resultados

Una mayor penetración de internet per cápita no garantiza automáticamente mejor rendimiento (caso Quibdó).

Predicción con RF

Random Forest Regressor permite identificar factores de intervención prioritaria. Métricas RMSE, MAE y R^2 evalúan la calidad predictiva.

Segmentación con K-Means

Los clusters identifican perfiles de necesidad diferenciada: de baja conectividad+bajo rendimiento a condiciones favorables.

Procesamiento Big Data

Apache Spark MLlib permite escalar el análisis y pasar de exploración descriptiva a modelos accionables de política pública.

LIMITACIONES

- Diferencias temporales entre fuentes de datos
- Promedio ICFES puede ocultar diferencias por área
- Variables clave ausentes (calidad docente, deserción)
- K-Means sensible a normalización de variables
- Relaciones descriptivas, no causales

TRABAJO FUTURO

- Incorporar más años para análisis temporal
- Añadir pobreza, deserción, ruralidad, calidad inst.
- Probar Gradient-Boosted Trees y regresión regularizada
- Modelo de clasificación: estudiantes en riesgo
- BONO: Red neuronal profunda vs Random Forest

GRACIAS

Procesamiento de Alto Volumen de Datos · Entrega 2

Grupo 16 · Pontificia Universidad Javeriana · 2026

6 FUENTES

8 PREGUNTAS

2 MODELOS ML

7 RECOMENDACIONES

CRISP-DM

APACHE SPARK

MLLIB

RANDOM FOREST

K-MEANS

SILHOUETTE

John Corredor, PhD