

Pontificia Universidad Javeriana

Facultad de Ingeniería
Departamento de Ingeniería de Sistemas

Proyecto de Investigación Big Data

Entrega 2: Preparación de datos, modelado y presentación de resultados

Asignatura: Procesamiento de Alto Volumen de Datos

Docente: John Corredor, PhD

Grupo: Grupo 16

Integrantes: Ana Sofía Arboleda, Alejandro Molina, Miguel Espinosa, Nicolas Torres

Fecha: 2026

Bogotá D.C., Colombia

Índice

1. Introducción	4
2. Objetivo de negocio	4
3. Metodología de trabajo	5
4. Fuentes de datos utilizadas	6
5. Filtros y transformaciones finales	6
5.1. Filtro 1: validación de registros con puntajes críticos	7
5.2. Filtro 2: eliminación de columnas redundantes o innecesarias	7
5.3. Transformación 1: tratamiento de valores faltantes	8
5.4. Transformación 2: integración de fuentes de datos	8
5.5. Transformación 3: creación de la variable de internet per cápita	9
5.6. Síntesis del punto 1	9
6. Respuesta a preguntas de negocio	10
6.1. PB1: Evolución de accesos y tecnologías por municipio	10
6.2. PB2: Relación entre internet en el hogar y rendimiento ICFES	11
6.3. PB3: Diferencia de puntajes controlando por municipio y estrato	12
6.4. PB4: Relación entre SGP Educación y resultados Saber 11	12
6.5. PB5: Infraestructura física de bibliotecas ante baja conectividad	13
6.6. PB6: Efecto del riesgo territorial en la brecha educativa	13
6.7. PB7: Combinación socioeconómica con mayor relación con el puntaje	14
6.8. PB8: Oferta de educación superior y rendimiento en media	15
6.9. Síntesis del punto 2	15
7. Selección de técnicas de aprendizaje de máquina	16

7.1. Técnica supervisada: Random Forest Regressor	16
7.2. Técnica no supervisada: K-Means	16
8. Preparación de datos para modelado	17
8.1. Selección de variables	17
8.2. Análisis de correlación	18
8.3. Codificación de variables categóricas	19
8.4. Normalización de variables numéricas	20
8.5. Construcción del vector de características	20
9. Aplicación de técnicas con Spark MLlib	21
9.1. Modelo supervisado: Random Forest Regressor	21
9.2. Modelo no supervisado: K-Means	22
10.Métricas y pruebas con diferentes parámetros	23
10.1. Métricas del modelo supervisado	23
10.1.1. RMSE: Root Mean Squared Error	23
10.1.2. MAE: Mean Absolute Error	24
10.1.3. R^2 : Coeficiente de determinación	24
10.2. Pruebas de parámetros para Random Forest	25
10.3. Métrica del modelo no supervisado: Silhouette	26
10.4. Pruebas con diferentes valores de K	27
10.5. Interpretación de clusters	28
11.Análisis integral de resultados	29
12.Recomendaciones al Ministerio de Educación	30
13.Conclusiones	31
14.Limitaciones del análisis	32

15.Trabajo futuro	32
16.Evidencia de cumplimiento del enunciado	33
17.Referencias	33
A. Anexo A: código base de modelado	35
B. Anexo B: lista de figuras sugeridas	35

1. Introducción

El presente documento corresponde a la segunda entrega del proyecto de investigación Big Data desarrollado bajo la metodología CRISP-DM. El proyecto se plantea desde un escenario de consultoría para el Ministerio de Educación, en el cual se busca analizar la relación entre los resultados académicos de las pruebas ICFES Saber 11 y diferentes condiciones territoriales, tecnológicas, sociales y presupuestales de los municipios seleccionados.

En la primera entrega se realizó el entendimiento del negocio, la selección de fuentes de datos, la descripción inicial de los conjuntos de datos, la exploración descriptiva y el planteamiento de preguntas de negocio. En esta segunda entrega se culmina el proceso de limpieza y transformación, se responden las preguntas de negocio propuestas y se incorporan técnicas de aprendizaje de máquina mediante Apache Spark MLlib.

El análisis se enfoca en identificar patrones asociados al rendimiento académico, especialmente aquellos relacionados con acceso a internet, disponibilidad de computador en el hogar, estrato socioeconómico, presupuesto educativo, riesgo territorial, bibliotecas públicas y oferta de educación superior. A partir de estos elementos se construyen modelos supervisados y no supervisados que permiten enriquecer la interpretación del problema y proponer recomendaciones orientadas a la toma de decisiones públicas.

Nota metodológica

El informe fue construido para acompañar el notebook del proyecto. Las tablas de métricas deben actualizarse con los valores que entregue la ejecución final del cuaderno en el clúster o ambiente Spark del equipo.

2. Objetivo de negocio

El objetivo de negocio consiste en apoyar al Ministerio de Educación en la generación de un plan de acción basado en procesamiento de datos para mejorar indicadores educativos territoriales. En particular, se busca comprender cómo la conectividad municipal y del hogar, junto con condiciones socioeconómicas y territoriales, se relacionan con el desempeño de los estudiantes en las pruebas ICFES Saber 11.

Desde la perspectiva del equipo consultor, el propósito es entregar evidencia analítica que permita:

- Identificar municipios con mayores brechas de conectividad y rendimiento académico.
- Analizar si el acceso a internet en el hogar se asocia con mejores puntajes promedio.
- Evaluar si variables como estrato, computador en casa, origen institucional, presupuesto educativo y riesgo ambiental influyen en los resultados.
- Construir modelos de aprendizaje de máquina que permitan predecir el rendimiento académico y segmentar perfiles de estudiantes o municipios.
- Formular recomendaciones para focalizar intervenciones educativas y tecnológicas.

3. Metodología de trabajo

La metodología seguida corresponde a CRISP-DM, adaptada al contexto de procesamiento de alto volumen de datos con Spark. Para esta entrega se desarrollan principalmente las fases de preparación de datos, modelado y evaluación.

Tabla 1: Relación entre CRISP-DM y la Entrega 2

Fase CRISP-DM	Aplicación en el proyecto
Entendimiento del negocio	Definición del problema del Ministerio de Educación y de las preguntas de negocio.
Entendimiento de los datos	Integración de datos de ICFES, internet, SGP, riesgo, bibliotecas y educación superior.
Preparación de datos	Limpieza, filtros, imputación, transformación, creación de variables y normalización.
Modelado	Aplicación de Random Forest Regressor y K-Means con Spark MLlib.
Evaluación	Cálculo de RMSE, MAE, R^2 y Silhouette; comparación de parámetros.
Presentación	Análisis de resultados, conclusiones y recomendaciones para el Ministerio.

4. Fuentes de datos utilizadas

El proyecto utiliza diferentes fuentes de datos que permiten analizar el problema educativo desde varias dimensiones.

Tabla 2: Conjuntos de datos utilizados en el proyecto

Fuente	Variables principales	Razón de uso
ICFES Saber 11	Puntajes por módulo, municipio de residencia, estrato, internet, computador, origen institucional	Permite medir el rendimiento académico y relacionarlo con condiciones del estudiante.
Internet por municipio	Municipio, año, tecnología, número de accesos	Permite medir conectividad territorial y comparar acceso digital entre municipios.
SGP Educación	Año, prestación de servicios, calidad, gratuidad, matrícula	Permite aproximar la inversión pública educativa por municipio.
Índice Municipal de Riesgo	Exposición a sequía extrema y variables de riesgo territorial	Permite analizar si condiciones ambientales y de riesgo inciden indirectamente en el aprendizaje.
Bibliotecas públicas	Municipio, nombre de biblioteca, ubicación	Permite evaluar la infraestructura física de acceso a información.
Educación superior	Municipio, matrícula universitaria	Permite analizar si la oferta de educación superior se relaciona con el ecosistema educativo local.

5. Filtros y transformaciones finales

El primer componente de esta entrega consistió en aplicar filtros y transformaciones finales sobre las fuentes de datos utilizadas en el proyecto. El objetivo de esta etapa fue mejorar la calidad de los datos, reducir información redundante, preparar variables relevantes e integrar

distintas fuentes para responder las preguntas de negocio planteadas.

En el notebook se aplicaron dos filtros principales y tres transformaciones orientadas a la limpieza, integración y enriquecimiento de los datos. Estas operaciones permitieron pasar de fuentes separadas a conjuntos de datos más adecuados para el análisis descriptivo.

5.1. Filtro 1: validación de registros con puntajes críticos

El primer filtro se aplicó sobre el conjunto de datos del ICFES, con el propósito de conservar únicamente los registros que tuvieran información válida en variables académicas centrales. En particular, se verificó la existencia de puntajes en Lectura Crítica y Razonamiento Cuantitativo, debido a que estas variables son fundamentales para analizar el rendimiento académico de los estudiantes.

```
icfes_filtrado_f1 = icfes_df.filter(  
    col("MOD_LECTURA_CRITICA_PUNT").isNotNull() &  
    col("MOD_RAZONA_CUANTITAT_PUNT").isNotNull()  
)
```

Este filtro permitió validar la consistencia de los registros académicos antes de realizar análisis posteriores. En la ejecución del notebook, el filtro no eliminó registros, lo cual indica que las columnas seleccionadas no presentaban valores nulos en los datos procesados. Aun así, su aplicación es importante porque garantiza que el análisis no dependa de registros incompletos en variables esenciales.

5.2. Filtro 2: eliminación de columnas redundantes o innecesarias

El segundo filtro consistió en eliminar columnas que no aportaban valor analítico directo para las preguntas de negocio. En el caso del conjunto SGP, se eliminaron columnas generadas por errores de lectura o sin contenido relevante, como `Unnamed: 5` y `Unnamed: 6`. En el conjunto ICFES, se eliminaron variables asociadas a códigos o campos administrativos que no eran necesarias para el análisis planteado.

```
sgp_filtrado_f2 = sgp_df.drop("Unnamed: 5", "Unnamed: 6")
```

```
icfes_filtrado_f2 = icfes_filtrado_f1.drop(  
    "ESTU_COD_COLE_MCPPIO_TERMINO",
```

```
"ESTU_CODDANE_COLE_TERMINO",  
"ESTU_COLE_TERMINO"  
)
```

La eliminación de estas columnas permitió reducir ruido en los datos, mejorar la legibilidad de los conjuntos procesados y enfocar el análisis en variables con utilidad directa para responder las preguntas de negocio.

5.3. Transformación 1: tratamiento de valores faltantes

Después de aplicar los filtros iniciales, se realizó un tratamiento de valores faltantes. Para algunas variables categóricas del conjunto ICFES se asignaron valores por defecto, con el fin de evitar la pérdida innecesaria de registros y mantener un volumen de datos adecuado para el análisis.

```
icfes_transformado_t1 = icfes_filtrado_f2.fillna({  
    "FAMI_TIENEINTERNET": "No",  
    "FAMI_TIENECOMPUTADOR": "No",  
    "FAMI ESTRATOVIVIENDA": "Estrato 1"  
})
```

Esta transformación permitió completar información faltante en variables familiares relevantes, como disponibilidad de internet, computador en el hogar y estrato socioeconómico. Sin embargo, es importante tener en cuenta que algunos valores pueden aparecer como NaN y no necesariamente como valores nulos de Spark. Por esta razón, la imputación debe verificarse cuidadosamente en la salida del notebook antes de afirmar que el conjunto quedó completamente libre de valores faltantes.

5.4. Transformación 2: integración de fuentes de datos

Una transformación central del proyecto fue la unión de diferentes fuentes de datos mediante variables comunes como municipio y año. Para mejorar la calidad de los cruces, se normalizaron los nombres de municipios usando funciones como `trim` y `upper`, reduciendo problemas derivados de espacios, mayúsculas, minúsculas o diferencias menores en la escritura.

```
join_icfes_internet = icfes_transformado_t1.join(
```

```

internet_df,
trim(upper(icfes_transformado_t1.ESTU_MCPIO_RESIDE)) ==
trim(upper(internet_df.MUNICIPIO)),
"inner"
)

```

En esta etapa se integraron principalmente datos de ICFES, conectividad, SGP e índice de riesgo territorial. Posteriormente, para responder preguntas específicas de negocio, se realizaron cruces adicionales con datos de bibliotecas públicas y educación superior.

Esta integración fue necesaria porque el problema de negocio no puede analizarse únicamente desde los resultados académicos. Para comprender mejor el rendimiento en las pruebas Saber 11, fue necesario relacionarlo con condiciones territoriales, tecnológicas, socioeconómicas y presupuestales.

5.5. Transformación 3: creación de la variable de internet per cápita

Con el fin de comparar la conectividad entre municipios de diferente tamaño poblacional, se creó la variable `INTERNET_PER_CAPITA_1000`. Esta variable expresa el número de accesos a internet por cada 1000 habitantes del municipio.

$$INTERNET_PER_CAPITA_1000 = \frac{\text{Número de accesos}}{\text{Población municipal}} \times 1000$$

```

master_analitico_df = master_df.withColumn(
    "INTERNET_PER_CAPITA_1000",
    (col("NO DE ACCESOS") / col("POBLACION_MUNICIPIO")) * 1000
)

```

Esta transformación es relevante porque comparar únicamente el número absoluto de accesos puede generar interpretaciones equivocadas. Un municipio con mayor población puede tener más accesos totales, pero menor cobertura relativa. Por ello, la medida per cápita permite una comparación más justa entre territorios.

5.6. Síntesis del punto 1

En conjunto, los filtros y transformaciones permitieron mejorar la calidad de los datos, reducir columnas innecesarias, tratar valores faltantes, integrar fuentes diversas y crear una

variable territorial de conectividad más comparable entre municipios. Estas operaciones fueron fundamentales para construir una base analítica más sólida y responder las preguntas de negocio con una perspectiva territorial, tecnológica y educativa.

6. Respuesta a preguntas de negocio

En esta sección se presentan las respuestas a las preguntas de negocio definidas para el proyecto. El análisis se desarrolló a partir de los datos procesados en el notebook, combinando información de rendimiento académico, conectividad, condiciones del hogar, presupuesto educativo, riesgo territorial, bibliotecas públicas y educación superior.

Es importante aclarar que los resultados presentados corresponden a asociaciones descriptivas observadas en los datos. Por tanto, no deben interpretarse como relaciones causales directas, sino como patrones útiles para orientar la toma de decisiones.

6.1. PB1: Evolución de accesos y tecnologías por municipio

La primera pregunta de negocio buscó analizar cómo han evolucionado los accesos a internet por tecnología en los municipios seleccionados. El análisis permitió observar diferencias en la composición tecnológica de la conectividad municipal.

En el caso de Buenaventura, se identificó una alta participación de tecnologías tradicionales como XDSL, seguida por Cable y otras tecnologías. Esto sugiere que la brecha digital no depende únicamente de la cantidad de accesos, sino también del tipo de tecnología disponible.

Tabla 3: Resultado PB1: accesos por tecnología en Buenaventura

Año	Municipio	Tecnología	Interpretación	Total accesos
2017	Buenaventura	XDSL	Alta dependencia de red tradicional	211722715
2017	Buenaventura	Cable	Alternativa secundaria	44223267
2017	Buenaventura	Otras tecnologías	Participación menor	29029733
2017	Buenaventura	Fiber to the Cabinet	Tecnología de fibra parcial	14051649
2017	Buenaventura	Otras tecnologías	Participación baja	6493663

El resultado indica que algunos municipios pueden tener acceso a internet, pero mediante tecnologías que no necesariamente ofrecen la misma calidad, estabilidad o capacidad para apoyar procesos educativos digitales. Por ello, la política pública no debería centrarse sola-

mente en aumentar el número de conexiones, sino también en mejorar la calidad tecnológica de la conectividad.

6.2. PB2: Relación entre internet en el hogar y rendimiento ICFES

La segunda pregunta analizó la relación entre tener internet en el hogar y el rendimiento promedio en las pruebas ICFES. Para esto, en el notebook se construyó una variable de promedio académico a partir de los puntajes disponibles en los módulos evaluados por el ICFES. Esta variable permitió resumir el desempeño general de los estudiantes y comparar los resultados entre quienes tenían internet en el hogar y quienes no.

$$PROMEDIO = \frac{\text{Inglés} + \text{Lectura Crítica} + \text{Razonamiento Cuantitativo} + \text{Comunicación Escrita} + \text{Comp}}{5}$$

Tabla 4: Resultado PB2: internet en el hogar y rendimiento ICFES

Municipio	Internet en hogar	Internet per cápita promedio	Rendimiento ICFES
Buenaventura	Sin información	0.1467283946	120.3779817
Buenaventura	No	0.1467283946	126.3321001
Buenaventura	Sí	0.1467283947	130.2170239
Quibdó	Sin información	0.5330947114	110.8088542
Quibdó	No	0.5330947115	115.2640741

En Buenaventura, los estudiantes con internet en el hogar presentaron un rendimiento promedio de 130.22, mientras que quienes no tenían internet obtuvieron 126.33. En Quibdó, dentro de los datos visibles, los estudiantes sin internet registraron un promedio de 115.26, superior al grupo sin información, que obtuvo 110.81.

El resultado permite afirmar que existe una asociación positiva entre disponibilidad de internet en el hogar y rendimiento académico, especialmente visible en Buenaventura. Sin embargo, esta relación no debe interpretarse como causalidad directa, ya que también pueden influir variables como estrato, computador en el hogar, tipo de institución y contexto familiar.

6.3. PB3: Diferencia de puntajes controlando por municipio y estrato

La tercera pregunta cruzó municipio, estrato socioeconómico e internet en el hogar. El objetivo fue observar si el acceso a internet se relaciona con diferencias de rendimiento dentro de grupos socioeconómicos específicos.

Tabla 5: Resultado PB3: estrato, internet y rendimiento

Municipio	Estrato	Internet en hogar	Comparación	Puntaje p
Buenaventura	Estrato 1	Sin información	Menor desempeño dentro del estrato	123
Buenaventura	Estrato 1	No	Desempeño intermedio	126
Buenaventura	Estrato 1	Sí	Mayor desempeño dentro del estrato	129
Buenaventura	Estrato 2	Sin información	Menor desempeño relativo	121
Buenaventura	Estrato 2	No	Desempeño superior al grupo sin información	126

En el caso de Buenaventura, dentro del Estrato 1 se observa una diferencia progresiva: el grupo sin información registra 123.71, el grupo sin internet 126.66 y el grupo con internet 129.40. Esto sugiere que la conectividad en el hogar puede estar asociada con mejores resultados incluso dentro de un mismo estrato.

Aun así, el acceso a internet no elimina por completo las desigualdades estructurales. La conectividad puede mejorar oportunidades de aprendizaje, pero necesita complementarse con dispositivos, acompañamiento pedagógico y condiciones familiares adecuadas.

6.4. PB4: Relación entre SGP Educación y resultados Saber 11

La cuarta pregunta buscó analizar la relación entre los recursos del Sistema General de Participaciones destinados a educación y el rendimiento promedio en Saber 11.

Tabla 6: Resultado PB4: SGP Educación y rendimiento académico

Municipio	Asignación SGP	Penetración internet	Rendimiento ICFES
Riohacha	Calidad	0.1563311054	132.2333695
Buenaventura	Calidad	0.1467283946	128.8906939
Quibdó	Calidad	0.5330947114	118.2893212

El análisis muestra que una mayor conectividad per cápita no necesariamente se traduce en mayor rendimiento académico. Quibdó presenta la mayor penetración de internet dentro

de estos tres municipios, pero también el menor rendimiento promedio. Esto indica que la inversión educativa y la conectividad deben analizarse junto con otros factores sociales, institucionales y pedagógicos.

Por tanto, la asignación presupuestal por sí sola no garantiza mejores resultados académicos de manera automática. Su efecto depende de cómo se articule con infraestructura tecnológica, calidad institucional, continuidad pedagógica y condiciones sociales del territorio.

6.5. PB5: Infraestructura física de bibliotecas ante baja conectividad

La quinta pregunta evaluó si la presencia de bibliotecas públicas puede actuar como apoyo en municipios con baja conectividad. Para ello, se cruzó la cantidad de bibliotecas con indicadores de conectividad y rendimiento académico.

Tabla 7: Resultado PB5: bibliotecas, conectividad y rendimiento

Municipio	Total bibliotecas	Penetración internet	Rendimiento ICFES
Riohacha	2	0.1563311054	132.2333695
Buenaventura	3	0.1467283946	128.8906939

Los resultados muestran que Buenaventura tiene tres bibliotecas y una penetración de internet de 0.1467, mientras que Riohacha tiene dos bibliotecas y una penetración de 0.1563. A pesar de contar con menos bibliotecas, Riohacha presenta un rendimiento promedio mayor.

Esto indica que la cantidad de bibliotecas por sí sola no explica el rendimiento académico. Las bibliotecas pueden ser espacios de apoyo educativo, especialmente en contextos con baja conectividad residencial, pero su impacto depende de que cuenten con internet, equipos, horarios adecuados y acompañamiento para los estudiantes.

6.6. PB6: Efecto del riesgo territorial en la brecha educativa

La sexta pregunta incorporó variables de riesgo territorial, especialmente exposición a sequía extrema. El propósito fue observar si los municipios con mayor vulnerabilidad ambiental también presentan condiciones educativas más débiles.

Tabla 8: Resultado PB6: riesgo territorial, conectividad y rendimiento

Municipio	Exposición a sequía extrema	Conectividad	Rendimiento ICFES
Quibdó	0.74	0.5330947114	118.2893212
Riohacha	0.67	0.1563311054	132.2333695
Buenaventura	0.66	0.1467283946	128.8906939

Quibdó presenta la mayor exposición a sequía extrema y, al mismo tiempo, el menor rendimiento promedio entre los municipios comparados. Aunque también registra la mayor conectividad per cápita, esto no se refleja en mejores resultados académicos.

Este resultado refuerza la idea de que la brecha educativa no depende únicamente de la conectividad. El riesgo territorial puede afectar indirectamente el rendimiento académico al influir en la continuidad escolar, la infraestructura, la movilidad, la estabilidad familiar y la capacidad institucional.

6.7. PB7: Combinación socioeconómica con mayor relación con el puntaje

La séptima pregunta combinó variables como estrato, disponibilidad de computador, internet en el hogar y origen institucional. El objetivo fue identificar perfiles socioeconómicos asociados con mayores puntajes agregados.

Tabla 9: Resultado PB7: perfiles socioeconómicos y rendimiento agregado

Estrato	Computador	Internet	Origen institución	Rendimiento agregado	Volumen es
Estrato 4	Sí	No	No oficial – fundación	224.6000000	
Estrato 1	Sí	No	Oficial municipal	191.0000000	
Estrato 1	Sí	Sin información	No oficial – fundación	174.6000000	
Estrato 3	No	Sí	No oficial municipal	170.2000000	
Estrato 2	Sí	No	Oficial municipal	161.1893806	

El perfil con mayor rendimiento agregado corresponde a estudiantes de Estrato 4, con computador en el hogar, sin internet registrado y pertenecientes a una institución no oficial tipo fundación. Sin embargo, este resultado debe interpretarse con cuidado, porque puede estar influenciado por el tipo de institución, el tamaño del grupo y las condiciones socioeconómicas asociadas.

El volumen de estudiantes es una variable importante porque permite evaluar la representatividad de cada perfil. Un rendimiento alto puede ser menos generalizable si proviene de un grupo pequeño; en este caso, los grupos visibles tienen volúmenes considerables, pero aun así el análisis debe mantenerse como descriptivo y no causal.

6.8. PB8: Oferta de educación superior y rendimiento en media

La octava pregunta analizó si la oferta de educación superior en el municipio se relaciona con el rendimiento de la educación media. Para ello, se compararon indicadores de matrícula superior con el rendimiento promedio en Saber 11.

Tabla 10: Resultado PB8: educación superior y rendimiento en media

Municipio	Total matrícula superior	Rendimiento colegios media
Riohacha	237.1170000	132.2333695
Quibdó	192.9320000	118.2893212
Buenaventura	98.3630000	128.8906939

Riohacha presenta el mayor indicador de matrícula superior y también el mayor rendimiento promedio en educación media. Quibdó, aunque tiene una matrícula superior más alta que Buenaventura, registra el menor rendimiento académico. Buenaventura, por su parte, tiene el menor indicador de matrícula superior, pero supera a Quibdó en rendimiento.

Esto muestra que la oferta de educación superior puede estar asociada con un ecosistema educativo más fuerte, pero no explica por sí sola el desempeño de la educación media. La relación debe analizarse junto con condiciones institucionales, socioeconómicas, territoriales y de calidad educativa.

6.9. Síntesis del punto 2

Las preguntas de negocio muestran que el rendimiento académico está asociado con una combinación de factores tecnológicos, socioeconómicos, institucionales y territoriales. La conectividad en el hogar, la disponibilidad de computador, el estrato, el origen institucional, el presupuesto educativo, el riesgo territorial, las bibliotecas públicas y la oferta de educación superior aportan elementos relevantes para interpretar las brechas educativas.

El análisis permite concluir que las intervenciones públicas no deberían enfocarse en una sola dimensión. Mejorar el rendimiento académico requiere estrategias integrales que combinen co-

nectividad, dotación tecnológica, fortalecimiento institucional, acompañamiento pedagógico y focalización territorial.

7. Selección de técnicas de aprendizaje de máquina

El tercer componente de la Entrega 2 exige seleccionar una técnica supervisada y una no supervisada. Para este proyecto se seleccionaron Random Forest Regressor y K-Means.

7.1. Técnica supervisada: Random Forest Regressor

Se seleccionó Random Forest Regressor porque la variable objetivo **PROMEDIO** es numérica continua. El modelo permite estimar el puntaje promedio ICFES a partir de variables de conectividad, condiciones familiares, inversión educativa y riesgo territorial.

Ventajas principales:

- Maneja relaciones no lineales entre variables.
- Es robusto frente a ruido y valores atípicos moderados.
- Permite combinar variables numéricas y categóricas transformadas.
- Funciona de forma escalable en Spark MLlib.

Relación con el negocio: permite estimar qué tan predecible es el rendimiento académico a partir de condiciones territoriales y socioeconómicas. Si el modelo obtiene buen desempeño, puede apoyar la identificación de factores de intervención prioritaria.

7.2. Técnica no supervisada: K-Means

Se seleccionó K-Means porque permite agrupar registros con características similares sin usar una etiqueta objetivo. En este proyecto, los clusters pueden representar perfiles de estudiantes o municipios según conectividad, condiciones del hogar, inversión educativa, riesgo y rendimiento.

Ventajas principales:

- Facilita segmentar territorios o estudiantes en grupos interpretables.

- Permite identificar perfiles prioritarios para intervención.
- Es eficiente y escalable en grandes volúmenes de datos.
- Puede evaluarse mediante la métrica Silhouette.

Relación con el negocio: permite diseñar acciones diferenciadas. Por ejemplo, un cluster con baja conectividad y bajo rendimiento puede requerir conectividad subsidiada, dotación tecnológica y acompañamiento pedagógico.

8. Preparación de datos para modelado

La preparación para modelado transforma el *master analítico* en un conjunto de datos compatible con Spark MLlib. Esta etapa incluye selección de variables, tratamiento de correlación, codificación de variables categóricas, ensamblaje de características y normalización.

8.1. Selección de variables

Las variables seleccionadas responden tanto al criterio técnico como al criterio de negocio. Se incluyen variables directamente asociadas al rendimiento académico, conectividad, condiciones del hogar, contexto territorial e inversión.

Tabla 11: Variables seleccionadas para modelado

Variable	Tipo	Justificación de negocio
PROMEDIO	Numérica	Variable objetivo que representa rendimiento académico.
INTERNET_PER_CAPITA_1000	Numérica	Mide conectividad territorial ajustada por población.
NO DE ACCESOS	Numérica	Representa infraestructura absoluta de acceso a internet.
POBLACION_MUNICIPIO	Numérica	Controla diferencias de tamaño municipal.
SGP_CALIDAD_PRESUPUESTO	Numérica/categorizada	Aproxima inversión educativa pública.
Exposición a Sequia Extrema	Numérica	Representa vulnerabilidad territorial.
FAMI_TIENEINTERNET	Categorica	Mide conectividad en el hogar.
FAMI_TIENECOMPUTADOR	Categorica	Mide disponibilidad de equipo tecnológico.
FAMI ESTRATOVIVIENDA	Categorica	Aproxima condición socioeconómica.
INST_ORIGEN	Categorica	Diferencia instituciones oficiales y no oficiales.

8.2. Análisis de correlación

Se calculó la correlación entre variables numéricas para identificar redundancias fuertes. Si dos variables presentan correlación muy alta, se recomienda conservar la variable con mayor interpretabilidad de negocio.

```
from pyspark.ml.stat import Correlation
from pyspark.ml.feature import VectorAssembler

assembler_corr = VectorAssembler(
    inputCols=columnas_numericas,
    outputCol="features_corr"
)

df_corr = assembler_corr.transform(df_modelo).select("features_corr")
```

```
matriz_corr = Correlation.corr(df_corr, "features_corr", "pearson").head()  
[0]  
print(matriz_corr)
```

Listing 1: Cálculo de matriz de correlación en Spark




Figura 1: Matriz de correlación de variables numéricas

Criterio usado: se considera una correlación fuerte cuando el valor absoluto es superior a 0.85. En caso de encontrar variables fuertemente correlacionadas, se prioriza conservar la variable más útil para explicar el fenómeno educativo.

8.3. Codificación de variables categóricas

Las variables categóricas no pueden ingresar directamente al modelo. Por esta razón se usaron `StringIndexer` y `OneHotEncoder`.

```
from pyspark.ml.feature import StringIndexer, OneHotEncoder  
  
indexadores = [  
    StringIndexer(inputCol=c, outputCol=c + "_idx", handleInvalid="keep")  
    for c in columnas_categoricas  
]  
  
encoder = OneHotEncoder(  
    inputCols=[c + "_idx" for c in columnas_categoricas],  
    outputCols=[c + "_vec" for c in columnas_categoricas]  
)
```

Listing 2: Codificación de variables categóricas

8.4. Normalización de variables numéricas

Se aplicó `StandardScaler` para normalizar las variables numéricas y evitar que variables con escalas grandes dominen el entrenamiento.

```
from pyspark.ml.feature import StandardScaler

scaler = StandardScaler(
    inputCol="features_sin_escalar",
    outputCol="features",
    withStd=True,
    withMean=False
)
```

Listing 3: Normalización con `StandardScaler`

Justificación: la normalización es especialmente importante para K-Means, ya que este algoritmo se basa en distancias. Sin normalización, variables como población o número de accesos podrían dominar la formación de clusters.

8.5. Construcción del vector de características

Spark MLlib requiere una columna `features` con el vector de variables predictoras. Para esto se utilizó `VectorAssembler` y luego un `Pipeline`.

```
from pyspark.ml.feature import VectorAssembler
from pyspark.ml import Pipeline

assembler_features = VectorAssembler(
    inputCols=columnas_numericas + [c + "_vec" for c in
        columnas_categoricas],
    outputCol="features_sin_escalar"
)

pipeline_preparacion = Pipeline(
    stages=indexadores + [encoder, assembler_features, scaler]
)

modelo_preparacion = pipeline_preparacion.fit(df_modelo)
df_preparado = modelo_preparacion.transform(df_modelo)
```

Listing 4: Construcción del pipeline de preparación

9. Aplicación de técnicas con Spark MLlib

Esta sección corresponde al punto 5 de la Entrega 2: aplicar las técnicas seleccionadas sobre los datos con MLlib en el clúster o ambiente Spark.

9.1. Modelo supervisado: Random Forest Regressor

El modelo Random Forest se entrenó usando el 80 % de los datos para entrenamiento y el 20 % para prueba. La variable objetivo fue PROMEDIO.

```
from pyspark.ml.regression import RandomForestRegressor
from pyspark.ml.evaluation import RegressionEvaluator

train_df, test_df = df_preparado.randomSplit([0.8, 0.2], seed=42)

rf = RandomForestRegressor(
    featuresCol="features",
    labelCol="PROMEDIO",
    predictionCol="prediction",
    numTrees=50,
    maxDepth=5,
    seed=42
)

modelo_rf = rf.fit(train_df)
predicciones_rf = modelo_rf.transform(test_df)
predicciones_rf.select("PROMEDIO", "prediction").show(10)
```

Listing 5: Entrenamiento de Random Forest Regressor

Predicciones del modelo Random Forest

Tabla con valores reales y valores predichos.

Insertar aquí la captura o gráfica generada desde el notebook.

Figura 2: Predicciones del modelo Random Forest

Interpretación esperada: si las predicciones se aproximan a los valores reales del promedio ICFES, el modelo logra capturar parte de la relación entre conectividad, contexto territorial y rendimiento académico. Si las diferencias son altas, significa que faltan variables explicativas o que el fenómeno tiene mayor complejidad social y pedagógica.

9.2. Modelo no supervisado: K-Means

El modelo K-Means se aplicó para identificar grupos de registros con características similares. El modelo base se ejecutó con $k=3$, aunque posteriormente se comparan diferentes valores de k .

```
from pyspark.ml.clustering import KMeans
from pyspark.ml.evaluation import ClusteringEvaluator

kmeans = KMeans(
    featuresCol="features",
    predictionCol="cluster",
    k=3,
    seed=42
)

modelo_kmeans = kmeans.fit(df_preparado)
clusters = modelo_kmeans.transform(df_preparado)

clusters.select(
    "PROMEDIO",
    "INTERNET_PER_CAPITA_1000",
    "cluster"
).show(20, truncate=False)
```

Listing 6: Entrenamiento de K-Means

Asignación de clusters con K-Means

Tabla con registros asignados a cada cluster.

Insertar aquí la captura o gráfica generada desde el notebook.

Figura 3: Asignación de clusters con K-Means

Interpretación esperada: cada cluster representa un perfil de condiciones. Por ejemplo, puede existir un grupo con baja conectividad y bajo rendimiento, otro con mejor conectividad y rendimiento medio, y otro con condiciones más favorables.

10. Métricas y pruebas con diferentes parámetros

Esta sección corresponde al punto 6 de la Entrega 2. Se aplican métricas adecuadas para cada tipo de modelo y se realizan pruebas con diferentes parámetros.

10.1. Métricas del modelo supervisado

Para evaluar Random Forest Regressor se usaron RMSE, MAE y R^2 .

10.1.1. RMSE: Root Mean Squared Error

El RMSE mide el error cuadrático medio en la misma escala de la variable objetivo. Penaliza más los errores grandes.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (1)$$

Interpretación: mientras más bajo sea el RMSE, mejor es el modelo. Si el RMSE es alto respecto a la escala del puntaje, el modelo comete errores grandes de predicción.

10.1.2. MAE: Mean Absolute Error

El MAE mide el error absoluto promedio entre valores reales y predichos.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2)$$

Interpretación: indica en promedio cuántos puntos se equivoca el modelo. Es fácil de explicar porque mantiene la escala del puntaje.

10.1.3. R²: Coeficiente de determinación

El R² mide la proporción de variabilidad de la variable objetivo explicada por el modelo.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (3)$$

Interpretación: valores cercanos a 1 indican mayor capacidad explicativa. Valores cercanos a 0 indican que el modelo explica poca variabilidad del rendimiento.

```
evaluator_rmse = RegressionEvaluator(  
    labelCol="PROMEDIO",  
    predictionCol="prediction",  
    metricName="rmse"  
)  
  
evaluator_mae = RegressionEvaluator(  
    labelCol="PROMEDIO",  
    predictionCol="prediction",  
    metricName="mae"  
)  
  
evaluator_r2 = RegressionEvaluator(  
    labelCol="PROMEDIO",  
    predictionCol="prediction",  
    metricName="r2"  
)  
  
rmse_rf = evaluator_rmse.evaluate(predicciones_rf)  
mae_rf = evaluator_mae.evaluate(predicciones_rf)  
r2_rf = evaluator_r2.evaluate(predicciones_rf)
```

Listing 7: Cálculo de métricas de regresión

Tabla 12: Resultados del modelo Random Forest base

Métrica	Valor obtenido	Interpretación
RMSE	Completar con notebook	Error promedio penalizando errores grandes. Menor es mejor.
MAE	Completar con notebook	Error absoluto promedio en puntos de IC-FES. Menor es mejor.
R ²	Completar con notebook	Proporción de variabilidad explicada. Mayor es mejor.

10.2. Pruebas de parámetros para Random Forest

Se probaron diferentes combinaciones de `numTrees` y `maxDepth`. El objetivo fue evaluar si aumentar la complejidad del modelo mejora su capacidad predictiva.

```
resultados_rf = []

for num_trees in [20, 50, 100]:
    for max_depth in [3, 5, 8]:
        rf_temp = RandomForestRegressor(
            featuresCol="features",
            labelCol="PROMEDIO",
            predictionCol="prediction",
            numTrees=num_trees,
            maxDepth=max_depth,
            seed=42
        )
        modelo_temp = rf_temp.fit(train_df)
        pred_temp = modelo_temp.transform(test_df)
        rmse_temp = evaluador_rmse.evaluate(pred_temp)
        mae_temp = evaluador_mae.evaluate(pred_temp)
        r2_temp = evaluador_r2.evaluate(pred_temp)
        resultados_rf.append((num_trees, max_depth, rmse_temp, mae_temp,
                               r2_temp))
```

Listing 8: Prueba de parámetros en Random Forest

Tabla 13: Comparación de parámetros Random Forest

numTrees	maxDepth	RMSE	MAE	R ²
20	3	Completar	Completar	Completar
20	5	Completar	Completar	Completar
20	8	Completar	Completar	Completar
50	3	Completar	Completar	Completar
50	5	Completar	Completar	Completar
50	8	Completar	Completar	Completar
100	3	Completar	Completar	Completar
100	5	Completar	Completar	Completar
100	8	Completar	Completar	Completar

Criterio de selección: se selecciona como mejor configuración aquella que presente menor RMSE y MAE, y mayor R². Si dos configuraciones tienen resultados similares, se prefiere la menos compleja para evitar sobreajuste y reducir tiempo de cómputo.




Figura 4: Comparación de RMSE por configuración de Random Forest

10.3. Métrica del modelo no supervisado: Silhouette

Para evaluar K-Means se usó la métrica Silhouette, que mide qué tan separados y compactos son los clusters.

$$S(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (4)$$

Donde $a(i)$ es la distancia promedio del punto i con los puntos de su mismo cluster, y $b(i)$ es

la distancia promedio con el cluster más cercano.

Interpretación:

- Valores cercanos a 1 indican clusters bien separados.
- Valores cercanos a 0 indican clusters superpuestos.
- Valores negativos indican posibles asignaciones incorrectas.

```

evaluator_cluster = ClusteringEvaluator(
    featuresCol="features",
    predictionCol="cluster",
    metricName="silhouette"
)

silhouette_kmeans = evaluator_cluster.evaluate(clusters)
print("Silhouette KMeans base:", silhouette_kmeans)

```

Listing 9: Cálculo de Silhouette para K-Means

Tabla 14: Resultado del modelo K-Means base

Modelo	Silhouette	Interpretación
K-Means k=3	Completar con notebook	Mayor valor indica clusters más definidos.

10.4. Pruebas con diferentes valores de K

Se probaron diferentes valores de k para identificar el número de clusters más adecuado.

```

resultados_kmeans = []

for k in [2, 3, 4, 5, 6]:
    kmeans_temp = KMeans(
        featuresCol="features",
        predictionCol="cluster",
        k=k,
        seed=42
    )
    modelo_temp = kmeans_temp.fit(df_preparado)
    clusters_temp = modelo_temp.transform(df_preparado)
    silhouette_temp = evaluator_cluster.evaluate(clusters_temp)

```

```
resultados_kmeans.append((k, float(silhouette_temp)))
```

Listing 10: Pruebas con diferentes valores de k

Tabla 15: Comparación de valores de k en K-Means

k	Silhouette	Interpretación
2	Completar	Dos grupos: útil si se quiere segmentar en bajo/alto riesgo o bajo/alto rendimiento.
3	Completar	Tres grupos: permite interpretación baja, media y alta.
4	Completar	Mayor detalle, pero puede ser menos interpretable.
5	Completar	Segmentación más fina; revisar si aporta valor de negocio.
6	Completar	Puede generar clusters pequeños o difíciles de interpretar.

Criterio de selección: el valor de k debe elegirse combinando la métrica Silhouette con la interpretabilidad de negocio. No siempre el mayor Silhouette es automáticamente la mejor decisión si el número de clusters dificulta diseñar acciones públicas claras.

Comparación de Silhouette para distintos valores de k

Gráfica de línea con k en el eje x y Silhouette en el eje y.

Insertar aquí la captura o gráfica generada desde el notebook.

Figura 5: Comparación de Silhouette para distintos valores de k

10.5. Interpretación de clusters

Después de seleccionar el valor final de k, se agruparon las variables principales por cluster para identificar perfiles.

Tabla 16: Interpretación de clusters finales

Cluster	Rendimiento	Conectividad	Condición territorial	Acción sugerida
0	Completar con notebook	Completar	Completar	Intervención prioritaria si combina bajo rendimiento y baja conectividad.
1	Completar con notebook	Completar	Completar	Fortalecer continuidad académica y acceso a recursos digitales.
2	Completar con notebook	Completar	Completar	Mantener y escalar buenas prácticas educativas.

11. Análisis integral de resultados

Los resultados descriptivos y de modelado permiten formular una lectura integral del problema. En primer lugar, los análisis de negocio muestran que la conectividad del hogar se relaciona con mejores resultados académicos. En municipios con vulnerabilidades estructurales, como Buenaventura y Quibdó, la disponibilidad de internet y computador puede representar una ventaja significativa para el estudiante.

En segundo lugar, la conectividad municipal medida de forma per cápita permite comparar municipios con tamaños poblacionales distintos. Este enfoque es más justo que analizar únicamente el número absoluto de accesos, porque un municipio grande puede tener más conexiones totales pero menor cobertura relativa.

En tercer lugar, el presupuesto educativo y la infraestructura institucional no producen resultados automáticos si no se articulan con conectividad, condiciones familiares, dotación tecnológica y estrategias pedagógicas. El análisis de SGP evidencia que la inversión debe acompañarse de políticas concretas de acceso y uso educativo de tecnología.

El modelo supervisado Random Forest aporta una lectura predictiva. Si sus métricas son favorables, significa que las variables seleccionadas logran explicar parte importante del ren-

dimiento. Si las métricas son débiles, el resultado sigue siendo útil porque evidencia que el rendimiento académico requiere variables adicionales, como calidad docente, asistencia escolar, acceso a materiales, seguridad alimentaria, jornada escolar, infraestructura física y acompañamiento familiar.

El modelo no supervisado K-Means complementa el análisis porque no busca predecir, sino segmentar. Esta segmentación permite pasar de una política general a una política diferenciada. Los clusters pueden servir para identificar grupos de estudiantes o territorios con necesidades similares.

12. Recomendaciones al Ministerio de Educación

A partir de los hallazgos se proponen las siguientes recomendaciones:

1. **Priorizar conectividad residencial en territorios rezagados.** El internet en casa muestra relación con mejores resultados académicos, por lo que se recomienda fortalecer programas de conectividad subsidiada para estudiantes de bajos recursos.
2. **Complementar conectividad con dotación de dispositivos.** El computador en el hogar aparece como una variable relevante. No basta con tener red si el estudiante no tiene equipo para aprovecharla.
3. **Focalizar municipios mediante indicadores per cápita.** La conectividad debe analizarse ajustada por población para evitar comparaciones engañosas entre municipios grandes y pequeños.
4. **Integrar inversión SGP con metas tecnológicas y pedagógicas.** La inversión educativa debe asociarse a proyectos medibles de infraestructura, capacitación docente y recursos digitales.
5. **Usar clusters para diseñar intervenciones diferenciadas.** Cada grupo identificado por K-Means puede recibir una estrategia distinta según su nivel de conectividad, riesgo y rendimiento.
6. **Fortalecer bibliotecas y espacios públicos digitales.** En municipios con baja conectividad residencial, las bibliotecas pueden funcionar como nodos de acceso, siempre que cuenten con internet, equipos y acompañamiento.

7. **Incorporar riesgo territorial en la planeación educativa.** Municipios con mayor vulnerabilidad ambiental requieren estrategias de continuidad académica, conectividad resiliente y planes de contingencia.

13. Conclusiones

La segunda entrega permitió culminar la preparación de datos, responder las preguntas de negocio planteadas y aplicar técnicas de aprendizaje de máquina con Spark MLlib. El proyecto evidencia que el rendimiento académico no depende de un único factor, sino de la interacción entre conectividad, condiciones socioeconómicas, disponibilidad de dispositivos, origen institucional, inversión pública, infraestructura de apoyo y contexto territorial.

Desde el análisis descriptivo, se encontró que los estudiantes con internet en el hogar tienden a presentar mejores resultados promedio que aquellos sin conectividad. Asimismo, las variables relacionadas con computador en casa, estrato y origen institucional muestran diferencias relevantes en el rendimiento. Esto confirma que la brecha educativa tiene una dimensión digital, pero también social e institucional.

Desde el punto de vista del modelado, Random Forest Regressor permite construir una aproximación predictiva del puntaje promedio ICFES. Las métricas RMSE, MAE y R^2 permiten evaluar la calidad de dicha predicción. El RMSE muestra el error penalizando desviaciones grandes, el MAE expresa el error promedio en puntos y el R^2 indica qué proporción del rendimiento logra explicar el modelo. La comparación de diferentes combinaciones de `numTrees` y `maxDepth` permite seleccionar una configuración más adecuada y evita depender de un único experimento.

Por su parte, K-Means permite identificar grupos de registros con características similares. La métrica Silhouette permite evaluar si los clusters están bien separados. Este modelo es útil para el Ministerio porque permite diseñar acciones diferenciadas según perfiles de necesidad: grupos con baja conectividad y bajo rendimiento, grupos intermedios y grupos con mejores condiciones educativas.

En conclusión, el procesamiento de alto volumen de datos con Spark permite pasar de análisis descriptivos aislados a una visión integral del fenómeno educativo. El uso de modelos de aprendizaje de máquina no reemplaza la interpretación social del problema, pero sí ayuda a priorizar territorios, detectar perfiles de riesgo y orientar decisiones de política pública basadas en evidencia.

14. Limitaciones del análisis

Aunque el análisis permite obtener hallazgos relevantes, existen algunas limitaciones:

- Algunas variables provienen de fuentes diferentes y pueden tener diferencias temporales, de granularidad o de calidad.
- El promedio ICFES resume el rendimiento, pero puede ocultar diferencias entre áreas específicas del conocimiento.
- Las variables disponibles no capturan todos los factores que influyen en el aprendizaje, como calidad docente, asistencia, motivación o entorno familiar.
- K-Means depende de la escala de las variables, por lo que la normalización es fundamental.
- Los modelos deben interpretarse como apoyo a la decisión, no como explicación causal definitiva.

15. Trabajo futuro

Como trabajo futuro se propone:

- Incorporar más años de datos para analizar tendencias temporales.
- Agregar variables de pobreza, cobertura educativa, deserción, ruralidad y calidad institucional.
- Probar otros modelos supervisados como Gradient-Boosted Trees o regresión lineal regularizada.
- Evaluar modelos de clasificación para identificar estudiantes o municipios en riesgo de bajo rendimiento.
- Implementar el bono de aprendizaje profundo mediante una red neuronal, comparando su desempeño contra Random Forest.

16. Evidencia de cumplimiento del enunciado

Tabla 17: Matriz de cumplimiento de la Entrega 2

Punto	Requerimiento	Estado	Evidencia en el informe
1	Filtros y transformaciones finales, mínimo 2 filtros y 3 transformaciones	Cumplido	Sección 4
2	Responder preguntas de negocio con tablas y visuales	Cumplido	Sección 5
3	Seleccionar técnica supervisada y no supervisada	Cumplido	Sección 6
4a	Eliminar o analizar características fuertemente correlacionadas	Cumplido	Sección 7.2
4b	Normalizar variables numéricas	Cumplido	Sección 7.4
4c	Seleccionar variables según criterio de negocio	Cumplido	Sección 7.1
5	Aplicar técnicas con MLlib sobre Spark	Cumplido	Sección 8
6	Aplicar métricas y probar parámetros	Cumplido	Sección 9

17. Referencias

- Apache Spark. Documentación oficial de Spark MLlib.
- Instituto Colombiano para la Evaluación de la Educación - ICFES. Microdatos Saber 11.
- Ministerio de Educación Nacional. Datos de educación y matrícula.
- Ministerio de Tecnologías de la Información y las Comunicaciones. Datos de conectividad e internet por municipio.
- Departamento Nacional de Planeación. Datos del Sistema General de Participaciones y contexto territorial.
- Provost, F. y Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.

- Han, J., Kamber, M. y Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.

A. Anexo A: código base de modelado

```
# Division entrenamiento/prueba
train_df, test_df = df_preparado.randomSplit([0.8, 0.2], seed=42)

# Random Forest
rf = RandomForestRegressor(
    featuresCol="features",
    labelCol="PROMEDIO",
    predictionCol="prediction",
    numTrees=50,
    maxDepth=5,
    seed=42
)
modelo_rf = rf.fit(train_df)
predicciones_rf = modelo_rf.transform(test_df)

# Metricas
rmse_rf = evaluador_rmse.evaluate(predicciones_rf)
mae_rf = evaluador_mae.evaluate(predicciones_rf)
r2_rf = evaluador_r2.evaluate(predicciones_rf)

# K-Means
kmeans = KMeans(
    featuresCol="features",
    predictionCol="cluster",
    k=3,
    seed=42
)
modelo_kmeans = kmeans.fit(df_preparado)
clusters = modelo_kmeans.transform(df_preparado)
silhouette_kmeans = evaluador_cluster.evaluate(clusters)
```

Listing 11: Código base consolidado para puntos 5 y 6

B. Anexo B: lista de figuras sugeridas

1. Evolución de accesos por tecnología y municipio.
2. Puntaje promedio según internet en el hogar.
3. Puntaje promedio por estrato e internet.

4. Presupuesto SGP y rendimiento ICFES.
5. Bibliotecas públicas, conectividad y rendimiento.
6. Riesgo territorial y desempeño académico.
7. Perfiles socioeconómicos con mayor rendimiento.
8. Educación superior y rendimiento en media.
9. Matriz de correlación.
10. Comparación de RMSE por configuración Random Forest.
11. Comparación de Silhouette para distintos valores de k.
12. Perfil promedio de cada cluster.